Διαχείριση και Οπτικοποίηση Δεδομένων Μεγάλης Κλίμακας

Ομάδα: Δολαψάκη Μαρία-Μελίνα, Μανίκα Βασιλική

Η παρούσα εργασία πραγματεύεται την αξιολόγηση ξενοδοχείων βάσει των κριτικών που έχουν γίνει από πελάτες τους, αλλά δίνοντας βάση στο κείμενο που γράφουν και το συναίσθημα που έχουν όταν καταγράφουν την κριτική τους. Για τον σκοπό αυτό, χρησιμοποιήθηκε επεξεργασία φυσικής γλώσσας και ανάλυση συναισθήματος, καθώς και διάφορα στατιστικά μοντέλα.

Τα παραγόμενα αποτελέσματα είναι χρήσιμα τόσο για online πλατφόρμες ξενοδοχείων όσο και για τους πελάτες που θέλουν να βρουν ξενοδοχείο με κάποιο συγκεκριμένο χαρακτηριστικό. Ειδικότερα, η διαδικασία που υλοποιήθηκε βοηθάει στην στοχευμένη αναζήτηση των χρηστών, δηλαδή να μπορουν να βρουν το συγκεκριμένο χαρακτηριστικό χωρίς να πρέπει να διαβάσουν όλες τις κριτικές και τυχαία να “πέσουν” πάνω σε αυτό που επιζητούν. Κατα κάποιο τρόπο, πλέον οι χρήστες έχουν τη δυνατότητα να ελέγχουν τα αποτελέσματα αναζήτησης. Επιπλέον, όσον αφορα την αξιολόγηση των ξενοδοχείων που γίνεται αυτόματα από τις online πλατφόρμες, προτείνουμε έναν διαφορετικό τρόπο κατάταξης των ξενοδοχείων που θα λαμβάνει υπόψιν το συναίσθημα που δημιουργείται από μία κριτική και τις λέξεις που χρησιμοποιούνται στο κείμενο.

Πηγή Δεδομένων

Τα δεδομένα λήφθηκαν από την πλατφόρμα Kaggle σε αρχείο csv. Το αρχικό σύνολο δεδομένων περιέχει περίπου 515.000 κριτικές πελατών και βαθμολογίες για 1493 πολυτελή ξενοδοχεία σε ολόκληρη την Ευρώπη και την γεωγραφική θέση των ξενοδοχείων. Από τα αρχικά δεδομένα κρατήθηκαν τα ονόματα των ξενοδοχείων και οι κριτικές τους. Σημειώνεται ότι οι κριτικές αντλήθηκαν από την Booking.com.

Η διαδικασία υλοποιήθηκε σε προγραμματιστικό περιβάλλον Python και χρησιμοποιήθηκαν οι παρακάτω βασικές βιβλιοθήκες:

1. NLTK: η πιο διάσημη ενότητα python για τεχνικές NLP
2. Gensim: εργαλειοθήκη μοντελοποίησης θεμάτων και διανυσματικού χώρου
3. Scikit-learn: η πιο διαδεδομένη βιβλιοθήκη μηχανικής μάθησης python

Φόρτωση δεδομένων:

- Μετά την εισαγωγή των ακατέργαστων δεδομένων, κάθε κείμενο κριτικής χωρίζεται σε ένα θετικό και αρνητικό μέρος και γίνεται ομαδοποίηση αυτών.
- Από τις 515.000 κριτικές παίρνουμε τις 10.000, οι οποίες επιλέχθηκαν τυχαία.

Καθαρισμός δεδομένων:

Εάν ο χρήστης δεν αφήσει κανένα αρνητικό σχόλιο, αυτό εμφανίζεται ως "No Negative" στα δεδομένα μας και όμοια για τα θετικά σχόλια με την προεπιλεγμένη τιμή "No Positive". Τα δεδομένα αυτα αφαιρούνται από τα κείμενα των κριτικών.

Καθαρισμός κειμένου χρησιμοποιώντας την βιβλιοθήκη NLTK. Συγκεκριμένα, για να καθαρίσουμε τα δεδομένα κειμένου, καλέσαμε την προσαρμοσμένη συνάρτηση 'clean_text' που εκτελεί διάφορους μετασχηματισμούς:

- μετατρέπει όλα τα γράμματα του κειμένου σε μικρά

- χωρίζει το κείμενο σε tokens, δηλαδή σε λέξεις και αφαιρεί τα λογοπαίγνια
- αφαιρεί λέξεις που περιέχουν αριθμούς
- αφαιρει τα stop words όπως ‘the’, ’a’, ‘this’ κ.α.
- αφαιρεί κενές λέξεις-tokens
- ετικετοποίηση μέρους του λόγου (POS): εκχώρηση μιας ετικέτας σε κάθε λέξη για να καθοριστεί αν αντιστοιχεί σε ουσιαστικό, ρήμα κ.λπ. με χρήση της λεξικής βάσης δεδομένων WordNet.
- λημματοποίηση του κειμένου: μετατροπή κάθε λέξης στη ρίζα της (π.χ. rooms -> room, slept -> sleep)

Επεξεργασία χαρακτηριστικών κειμένου

Για την ανάλυση συναισθημάτων, χρησιμοποιήσουμε το Vader, ένα εργαλείο που ανήκει στη βιβλιοθήκη Natural Language Toolkit (NLTK). Το Vader χρησιμοποιεί ένα λεξικό λέξεων για να προσδιορίσει την θετικότητα ή αρνητικότητα μιας φράσης ή ενός κειμένου. Το εργαλείο λαμβάνει επίσης υπόψη το πλαίσιο των προτάσεων για να καθορίσει τη βαθμολογία των συναισθημάτων. Για κάθε κείμενο που αναλύουμε με το Vader, λαμβάνουμε τέσσερις τιμές:

1. **Compound Score**: Είναι ένας αριθμητικός δείκτης που υπολογίζεται βάσει του λεξικού και του πλαισίου των προτάσεων. Μεγαλύτερες τιμές υποδηλώνουν πιο θετικά συναισθήματα, ενώ μικρότερες τιμές υποδηλώνουν πιο αρνητικά συναισθήματα.
2. **Positive Score**: Είναι ο βαθμός θετικότητας του κειμένου, αναφορικά με το λεξικό. Πρόκειται για το ποσοστό των λέξεων του κειμένου που θεωρούνται θετικές.
3. **Negative Score**: Είναι ο βαθμός αρνητικότητας του κειμένου, αναφορικά με το λεξικό. Πρόκειται για το ποσοστό των λέξεων του κειμένου που θεωρούνται αρνητικές.
4. **Neutral Score**: Είναι ο βαθμός ουδετερότητας του κειμένου, αναφορικά με το λεξικό. Πρόκειται για το ποσοστό των λέξεων του κειμένου που θεωρούνται ουδέτερες.

Οι δείκτες συναισθήματος είναι στην κλίμακα 0-1 για τις στήλες ‘negative’ ‘neutral’, ‘positive’ και η τελική compound βρίσκει ένα μέσο όρο των τριών στηλών στην κλίμακα -1 έως 1. Μία ιδέα περαιτέρω διεύρυνσης της άσκησης είναι η δημιουργία βαρών σύμφωνα με τις στήλες αυτές ώστε να επηρεάζεται η στήλη Βαθμολογίας των Ξενοδοχείων. Αν πολλοί χρήστες γράφουν μία έντονα μία καλή κριτική για τη διαμονή τους, θα μπορούσε να αυξηθεί επιπλέον η βαθμολογία του ξενοδοχείου. Αν υπάρχουν αρκετές κριτικές με άσχημο συναίσθημα για ένα ξενοδοχείο, θα μπορούσε να μειωθεί η βαθμολογία του δραστικά χρησιμοποιώντας τα βάρη από τη στήλη των συναισθημάτων. Προτείνεται ως επόμενη εργασία η δημιουργία ενός νέας βάσης Rating.

Επιπλέον, για μία πιό ολοκληρωμένη αντίληψη της αξιολόγησης των κριτικών των πελατών σε συνδυασμό με την ανάλυση συναισθήματος, χρησιμοποιήθηκαν κι άλλες μετρικές για κάθε κείμενο όπως:

1. **Αριθμός χαρακτήρων στο κείμενο**: Μπορούμε να μετρήσουμε τον συνολικό αριθμό των χαρακτήρων σε ένα κείμενο, συμπεριλαμβανομένων των κενών. Αυτή η μετρική μπορεί να δώσει μια ιδέα για το μέγεθος του κειμένου και τη συνολική του πολυπλοκότητα.
2. **Αριθμός λέξεων στο κείμενο**: Μπορούμε να μετρήσουμε τον αριθμό των λέξεων που περιέχονται σε ένα κείμενο. Αυτή η μετρική μπορεί να μας δώσει μια ιδέα για τον όγκο του κειμένου και την πυκνότητα της πληροφορίας που περιέχει.

Στην συνέχεια, χρησιμοποίηθηκαν διανυσματικές αναπαραστάσεις για κάθε κριτική με τη βιβλιοθήκη Gensim με στόχοι την κατανόηση του περιεχόμενο και τη συσχέτιση των κριτικών των πελατών και την χρήση ως χαρακτηριστικά για την εκπαίδευση μοντέλων αναγνώρισης προτιμήσεων ή πρόβλεψης συναισθημάτων.
Για την αναπαράσταση λέξεων, χρησιμοποιήθηκε το μοντέλο Word2Vec, όπου οι παρόμοιες λέξεις θα έχουν παρόμοια διανύσματα αναπαράστασης.
Για την αναπαράσταση κειμένων, μπορούμε να χρησιμοποιήσουμε το μοντέλο Doc2Vec, όπου κείμενα που έχουν παρόμοιο περιεχόμενο θα έχουν κοντινά διανύσματα αναπαράστασης.

Τέλος, έγινε χρήση της μεθόδου TF-IDF (Term Frequency - Inverse Document Frequency) για κάθε λέξη και κάθε έγγραφο, η οποία χρησιμοποιείται για τον υπολογισμό της σχετικής σημασίας μιας λέξης σε ένα έγγραφο ή σύνολο εγγράφων. Δηλαδή, δίνει παραπάνω βαρύτητα σε λέξεις που εμφανίζονται πιο σπάνια μέσα στο κείμενο και λιγότερη σε λέξεις που εμφανίζονται συχνά, καθώς οι σπάνιες λέξεις μπορεί να περιέχουν περισσότερη πληροφορία σε σύγκριση με τις κοινές λέξεις που χρησιμοποιούνται. Η παράμερος TF υπολογίζει τον κλασικό αριθμό των φορών που εμφανίζεται η λέξη στο κείμενο και η IDF υπολογίζει τη σχετική σημασία αυτής της λέξης, η οποία εξαρτάται από το πόσα κείμενα μπορεί να βρεθεί η λέξη. Η σημαντικότητα μίας λέξης δεν εξαρτάται δηλαδή μόνο από τη συχνότητα εμφάνισης της, αλλά λαμβάνεται υπόψιν και η σπάνια χρήση μίας λέξης που μπορεί να προσδώσει και νέα στοιχεία. Η βαθμολογία σημαντικότητας κάθε μίας λέξης δίνεται από τους δείκτες df(t) = occurrence of t in documents, idf(t) = log(N/(df + 1)).

Κατά τον υπολογισμό του TF, όλοι οι όροι θεωρούνται εξίσου σημαντικοί. Ωστόσο, είναι γνωστό ότι ορισμένοι όροι, όπως“is”, “of”, and “that”, μπορεί να εμφανίζονται πολλές φορές αλλά έχουν μικρή σημασία. Έτσι, πρέπει να μειώσουμε τη βαρύτητα των συχνών όρων ενώ να αυξήσουμε τη βαρύτητα των σπάνιων όρων, με τον υπολογισμό του IDF, ενσωματώνεται ένας αντίστροφος παράγοντας συχνότητας εγγράφων, ο οποίος μειώνει τη βαρύτητα των όρων που εμφανίζονται πολύ συχνά στο σύνολο των εγγράφων και αυξάνει τη βαρύτητα των όρων που εμφανίζονται σπάνια.

Το IDF είναι το αντίστροφο της συχνότητας εγγράφων, το οποίο μετρά την πληροφοριακότητα του όρου t. Όταν υπολογίζουμε το IDF, θα είναι πολύ χαμηλό για τις λέξεις που εμφανίζονται συχνότερα, όπως οι λέξεις στάσης (επειδή οι λέξεις στάσης, όπως η λέξη "είναι", υπάρχουν σχεδόν σε όλα τα έγγραφα και το N/df θα δώσει πολύ χαμηλή τιμή σε αυτή τη λέξη). Αυτό τελικά δίνει αυτό που θέλουμε, μια σχετική βαρύτητα.

Περαιτέρω ανάλυση δεδομένων

Προκειμένου να κατανοήσουμε με περισσότερη ακρίβεια την συμπεριφορά των δεδομένων προχωρήσαμε σε επιπλέον ανάλυση αυτών.
Μέσω της εντολής:

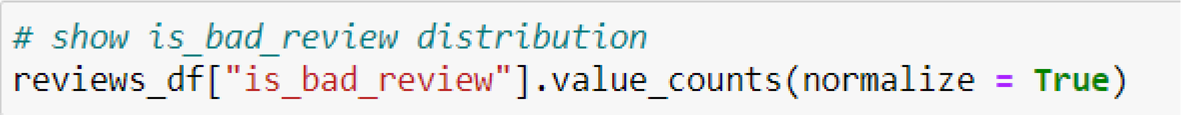

```
# show is_bad_review distribution
reviews_df["is_bad_review"].value_counts(normalize = True)
```

διαπιστώθηκε ότι το σύνολο δεδομένων είναι εξαιρετικά ανισόρροπο, επειδή λιγότερο από το 5% των κριτικών μας θεωρούνται αρνητικές. Αυτή η πληροφορία είναι αρκετά χρήσιμη για το κομμάτι της μοντελοποίησης.

Στην συνέχεια, με χρήση της συνάρτησης ‘wordcloud’ εκτυπώθηκαν οι λέξεις που εμφανίζονται στις κριτικές. Το μέγεθος των λέξεων είναι ανάλογο με την συχνότητα εμφάνισής τους μέσα στις κριτικές, δηλαδή οι λέξεις με μεγαλύτερο μέγεθος υποδηλώνουν ότι εμφανίζονται περισσότερο μέσα στο κείμενο.

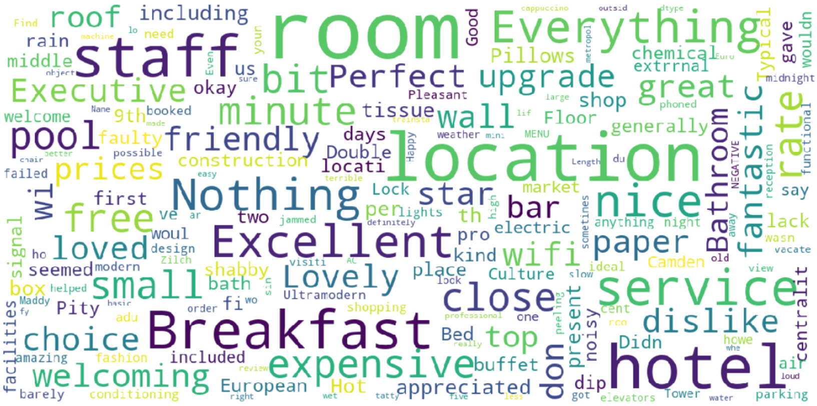

Είναι ευδιάκριτο, το γεγονό ότι οι περισσότερες λέξεις σχετίζονται πράγματι με τα ξενοδοχεία: room, staff, breakfast, κ.α. Επίσης, ορισμένες λέξεις σχετίζονται περισσότερο με την εμπειρία του πελάτη από τη διαμονή στο ξενοδοχείο: perfect, loved, expensive, dislike, κ.α.

Εν συνεχεία, έγινε εμφάνιση τριάντα κριτικών με την υψηλότερη θετική ‘pos’ και αρνητική ‘neg’ αξιολόγηση (σε φθίνουσα σειρά) από το DataFrame με την προϋπόθεση να περιέχουν περισσότερες από πέντε λέξεις. Ενδεικτικά παρουσιάζονται οι 15 πρώτες εξ’ αυτών:

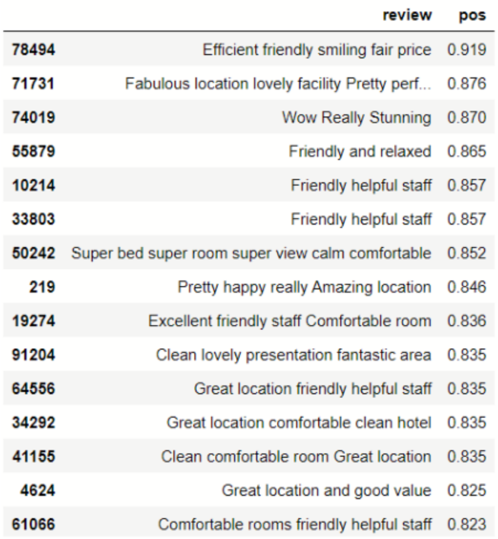

	review	pos
78494	Efficient friendly smiling fair price	0.919
71731	Fabulous location lovely facility Pretty perf...	0.876
74019	Wow Really Stunning	0.870
55879	Friendly and relaxed	0.865
10214	Friendly helpful staff	0.857
33803	Friendly helpful staff	0.857
50242	Super bed super room super view calm comfortable	0.852
219	Pretty happy really Amazing location	0.846
19274	Excellent friendly staff Comfortable room	0.836
91204	Clean lovely presentation fantastic area	0.835
64556	Great location friendly helpful staff	0.835
34292	Great location comfortable clean hotel	0.835
41155	Clean comfortable room Great location	0.835
4624	Great location and good value	0.825
61066	Comfortable rooms friendly helpful staff	0.823

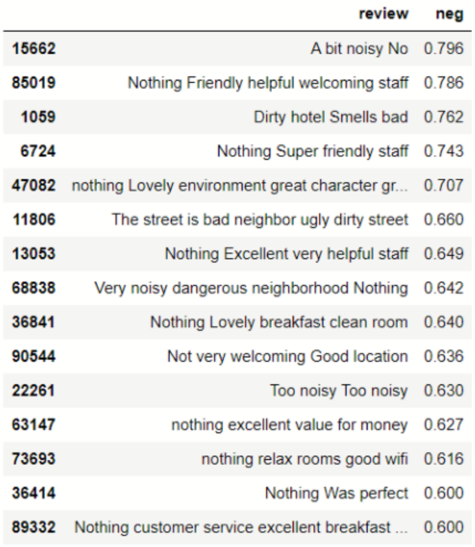

	review	neg
15662	A bit noisy No	0.796
85019	Nothing Friendly helpful welcoming staff	0.786
1059	Dirty hotel Smells bad	0.762
6724	Nothing Super friendly staff	0.743
47082	nothing Lovely environment great character gr...	0.707
11806	The street is bad neighbor ugly dirty street	0.660
13053	Nothing Excellent very helpful staff	0.649
68838	Very noisy dangerous neighborhood Nothing	0.642
36841	Nothing Lovely breakfast clean room	0.640
90544	Not very welcoming Good location	0.636
22261	Too noisy Too noisy	0.630
63147	nothing excellent value for money	0.627
73693	nothing relax rooms good wifi	0.616
36414	Nothing Was perfect	0.600
89332	Nothing customer service excellent breakfast ...	0.600

Αξιολόγηση αποτελεσμάτων

Το παρακάτω γράφημα απεικονίζει την κατανομή των συναισθηματικών αξιολογήσεων για θετικές και αρνητικές κριτικές. Χωρίστηκαν τα δεδομένα σε σετ εκπαίδευσης,επικύρωσης(validation) και τεστ, ώστε να εκπαιδευτεί ικανός ταξινομητής που θα εκπαιδευτεί ώστε να αναγνωρίζει το συναίσθημα κάθε κριτικής που θα του δωθεί από τα αρχικά δεδομένα. **Όπως φαίνεται, μεγάλο μέρος των κριτικών ανήκουν στην κατηγορία ‘neutral’, επομένως προτείνεται να μειωθεί το βάρος τους, καθώς δεν επηρεάζουν την**

αξιολόγηση και χάνεται έτσι η σημαντικότητα άλλων κριτικών με πιο έντονα συναισθήματα.

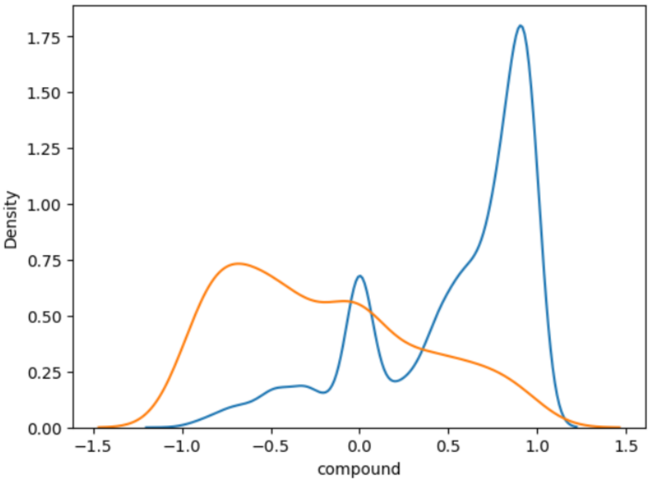

Επιπλέον, πραγματοποιήθηκε διαχωρισμός των δεδομένων σε training και test set και χρησιμοποιήθηκαν στην εκπαίδευση του Random Forest. Με βάση τον ταξινομητή Random Forest παρουσιάστηκαν τα 20 πρώτα χαρακτηριστικά με τον μεγαλύτερο δείκτη σημαντικότητας κατά φθίνουσα σειρά.

Καμπύλη ROC και γράφημα Precision-Recall

Από την μορφή των παρακάτω καμπυλών φαίνεται ότι εκπαιδεύτηκε αποδοτικά το μοντέλο της ανάλυσης συναισθήματος

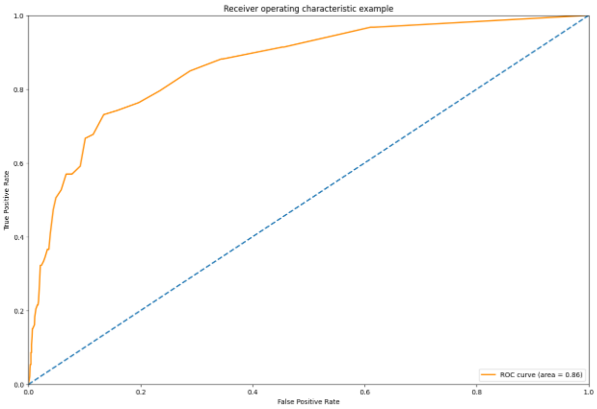

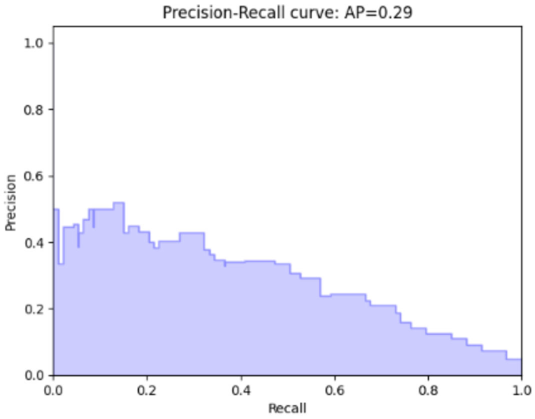

Στην συνέχεια, κατασκευάστηκε το **Target text= 'bad view awful smell bed'**. Ο σκοπός της δημιουργίας αυτού, ήταν βάσει των μεθόδων TF-IDF και cosine similarity να βρεθούν οι κριτικές που φέρουν μεγάλη ομοιότητα με το target text.

Έπειτα, πήραμε το ξενοδοχείο με τις περισσότερες αρνητικές κριτικές. Απο τις 460 κριτικές που είχαν γραφτεί για το συγκεκριμένο ξενοδοχείο, πήραμε τις 60 πιο σχετικές βάσει του **target text** που είχαμε φτιάξει παραπάνω με αρνητικό πρόσημο. Ο πίνακας συνεκτικότητας έδειξε ότι ο μέσος όρος έχει αρνητικό πρόσημο και ο μέσος όρος για το εν λόγω ξενοδοχείο είναι:

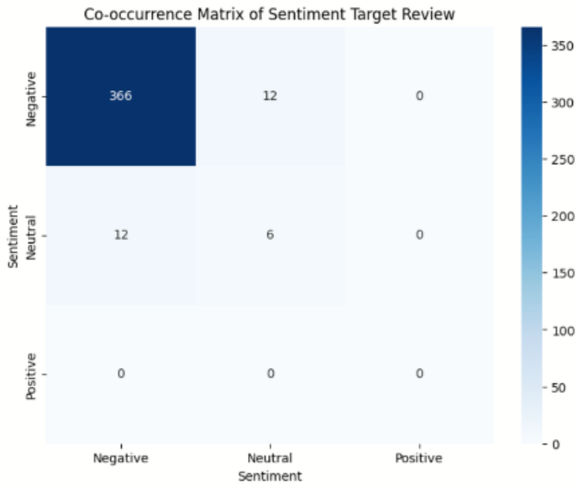

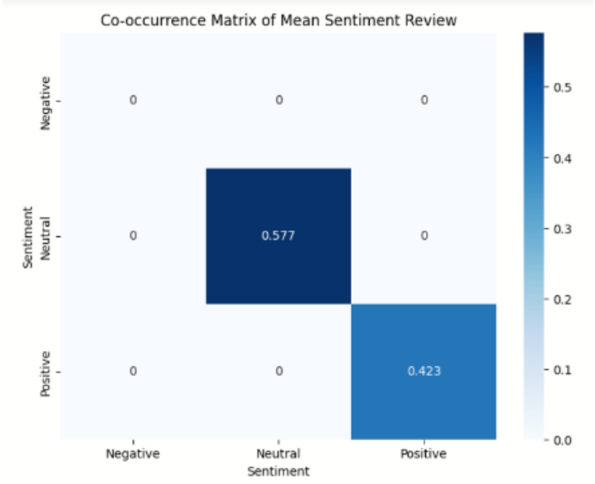

Ο πίνακας του μέσου όρου αναφέρεται στις 460 κριτικές έναντι των 60 που λέγανε τόσο αρνητικά σχόλια. Επομένως, είναι ξεκάθαρο το γεγονός οτι δεν λαμβάνεται υπόψη αυτή την στιγμή ιδιαίτερα οτι υπάρχουν τόσοι πελάτες με κακες εμπειρίες. Άρα, φαίνεται πόσο σημαντικό είναι να φτιαχτεί αλγόριθμος που να το λαμβάνει υπόψη αυτο. Στην παρούσα εργασία έχουν δημιουργηθεί αρκετα στατιστικά μοντέλα που θα βοηθήσουν στην υλοποίηση αυτου.

Τέλος, εκτελέσαμε διάγραμμα συνεκτικότητας των λέξεων στο **target text** και δημιουργήσαμε κοινότητες γύρω από τους κόμβους του συνόλου δεδομένων. Πήραμε τις 500 πρώτες λέξεις για αναφορά, για να εμφανίσουμε τη συχνότητα ή ένταση της συνύπαρξης μεταξύ των λέξεων-κλειδιών.. Στους γράφους χρησιμοποιώντας το compound, με κόκκινο χρώμα βάφτηκαν όσες κριτικές είχαν αρνητικό πρόσημο, με πράσινο οι θετικότερες και κίτρινο οι ουδέτερες, εκείνες πο είναι negative-positive και positive-negative από τη συμμεταβλητότητα του συνελικτικού πίνακα. Βρέθηκαν 64 communities συνολικά και εμφανίζεται η απόσταση των κόμβων από το target text, με το μπλε χρώμα. Από τα διαγράμματα φαίνεται ότι στο σύνολο των 500 λέξεων που χρησιμοποιήθηκαν βρέθηκαν 2 έντονα patterns των κόμβων, πολλοί κόμβοι μαζεμένοι στο κέντρο και άλλοι που ορίζουν μία γειτονιά γύρω από αυτά. Ο γράφος απεικονίζεται με τη χρήση ενός αλγορίθμου διάταξης "spring layout algorithm", όπου οι κόμβοι με μεγαλύτερη συν-εμφάνιση τείνουν να βρίσκονται πιο κοντά μεταξύ τους. Οι κοινότητες του γράφου εντοπίζονται με τη χρήση ενός άπληστου modularity αλγορίθμου, ο οποίος ομαδοποιεί τις λέξεις-κλειδιά που συναντώνται συχνά. Οι απομακρυσμένοι κόμβοι, βάφτηκαν γαλάζιοι, ασχέτως από το συναίσθημα που εκφράζουν, αν και για εμάς είναι προφανές ότι αναφέρεται σε θετικές κριτικές- αφού έχουν μεγάλη αποσταση από τον κόμβο target text που δηλώσαμε να αναφέρεται σε αρνητικές λέξεις.

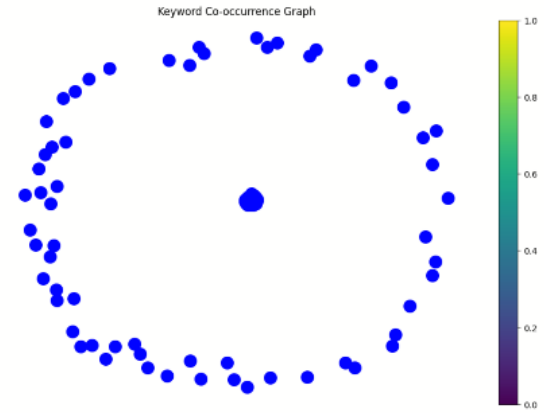

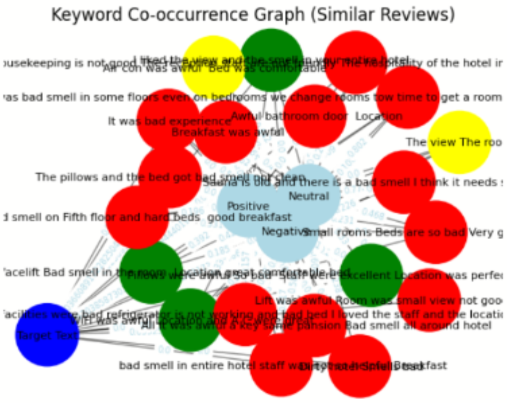
Keyword Co-occurrence Graph (Similar Reviews)
Neutral
Positive
Negative
Target Text
It was bad experience
Breakfast was awful
Awful bathroom door
Location
The view The roo
The pillows and the bed got bad smell
good breakfast
Small rooms Beds are so bad Very g
bad smell in entire hotel
Lift was awful Room was small view not goo

Η αρχική επεξεργασία των δεδομένων λάμβανε υπόψιν και τις 500,000 εγγραφες κριτικών. Τελικά επειδή οι διαδικασίες ιδιαίτερα η εύρεση co-occurance matrix χρειάζονταν πάνω απο 20 λεπτά να ολοκληρωθούν, ή τερμάτιζαν τη διαθέσιμη μνήμη του Colab, έγινε προσπάθεια να χρησιμοποιηθεί η διαδικασία svd για να μειωθεί ο όγκος πληροφορίας που παράγεται. Δεν στεφτηκαν με επιτυχία οι προσπάθειες αυτές και έγιναν απόπειρες να μειώσουμε τον όγκο δεδομένων κάνοντας under-sampling στην εκπαίδευση, και να χρησιμοποιηθούν μόνο 10,000 εγγραφές ως αρχικά δεδομένα. Έτσι, τα γραφήματα και οι γειτονιές που βρίσκονται με τους γράφους μπορούν να γίνουν κατανοητά και να είναι δυνατή η επεξεργασία τους σε προσπελάσιμο χρόνο εκτέλεσης.

Αποδεικνύεται ότι η εργασία αυτή είναι αρκετά χρήσιμη, καθώς δίνει πολλές πληροφορίες και στατιστικά μοντέλα που μπορούν να χρησιμοποιηθούν για τη βελτίωση της εμπειρίας των χρηστών. Για παράδειγμα οι χρήστες μπορούν να αναζητήσουν ξενοδοχεία με τα χαρακτηριστικά που επιθυμούν. Η εταιρία του booking, επίσης, επωφελείται αν χρησιμοποιήσει τις προτεινόμενες μας λύσεις, όπως η χρήση sentimental analysis που επηρεάζει την βαθμολογία των ξενοδοχείων μπορεί να αναβαθμίσει τις υπηρεσίες του.