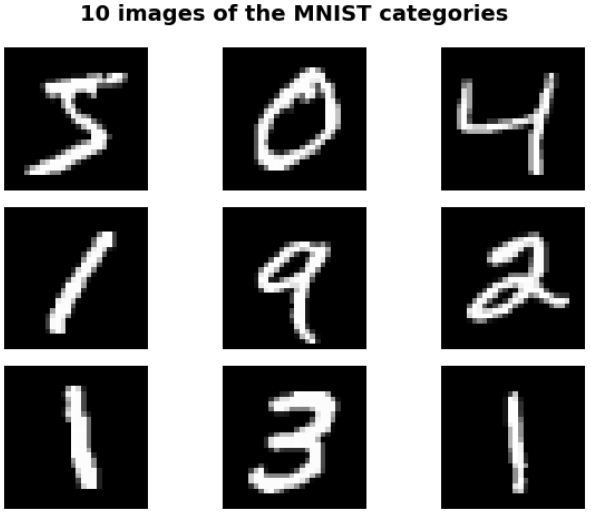
Comparing Basic

Για το δεύτερο μέρος της εργασίας, δημιουργήθηκαν δύο νευρωνικά δίκτυα για το classification του dataset Mnist, ένα CNN και ένα απλό FeedForward δίκτυο DNN. Θα παραχθούν γραφήματα που αποδεικνύουν την επιτυχία των αλγορίθμων, όπως και θα αναλυθεί περιεκτικά η διαδικασία που ακολουθήσαμε.

Το MNist είναι ένα δημοφιλές, balanced σύνολο δεδομένων που χρησιμοποιείται στον τομέα της μηχανικής μάθησης και της όρασης υπολογιστών. Αποτελείται από μια μεγάλη συλλογή χειρόγραφων ψηφίων από το 0 έως το 9, καθένα από τα οποία αναπαρίσταται ως εικόνα κλίμακας του γκρι μεγέθους 28x28 εικονοστοιχείων. Το σύνολο δεδομένων MNIST χρησιμοποιείται ευρέως ως σημείο αναφοράς για την ανάπτυξη και αξιολόγηση αλγορίθμων μηχανικής μάθησης, ιδίως για εργασίες ταξινόμησης εικόνων. Έχει μελετηθεί εκτενώς και έχει γίνει ένα τυπικό σύνολο δεδομένων για τη δοκιμή της απόδοσης διαφόρων μοντέλων, αλγορίθμων και τεχνικών. Το σύνολο δεδομένων χωρίζεται σε δύο κύρια μέρη: ένα σύνολο εκπαίδευσης και ένα σύνολο δοκιμής. Το σύνολο εκπαίδευσης περιέχει 60.000 παραδείγματα, ενώ το σύνολο δοκιμής περιέχει 10.000 παραδείγματα. Οι εικόνες στο σύνολο δεδομένων είναι επισημασμένες με το αντίστοιχο ψηφίο που αναπαριστούν, καθιστώντας το κατάλληλο για εργασίες μάθησης με επίβλεψη. Οι ερευνητές και οι επαγγελματίες χρησιμοποιούν συχνά το σύνολο δεδομένων MNIST για να αναπτύξουν και να συγκρίνουν διαφορετικές προσεγγίσεις στην αναγνώριση εικόνων, συμπεριλαμβανομένων μοντέλων βαθιάς μάθησης όπως τα συνελικτικά νευρωνικά δίκτυα (CNN). Η απλότητα και το μικρό μέγεθος του συνόλου δεδομένων το καθιστούν ένα καλό σημείο εκκίνησης για την εκμάθηση και τον πειραματισμό με αλγορίθμους ταξινόμησης εικόνων.



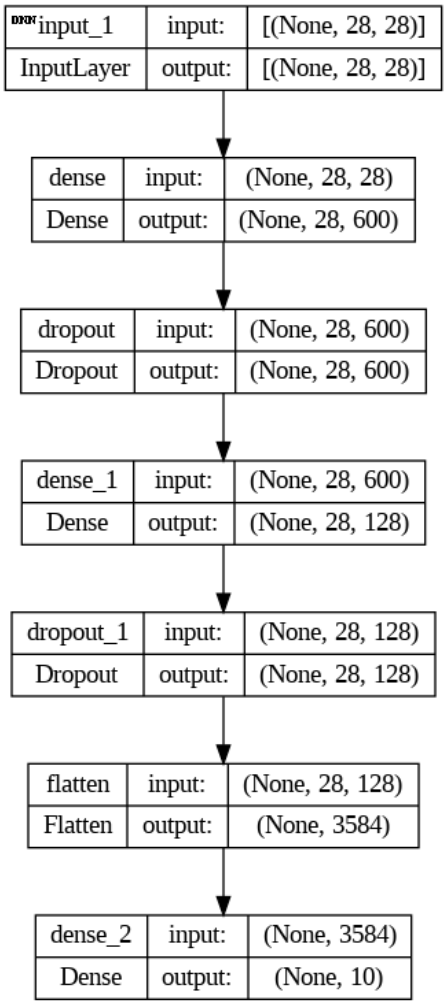
DNN Αρχιτεκτονική μοντέλου:
Αρχικά δημιουργήθηκε ένα DNN με απλή αρχιτεκτονική για την εξοικείωση με την διαδιδκασία παραγωγής τους. Η αρχιτεκτονική του μοντέλου DNN (βαθύ νευρωνικό δίκτυο) που εκπαιδευτηκε αποτελείται από τα ακόλουθα επίπεδα:

Dense Layer: Έχει 600 νευρώνες και το σχήμα εξόδου είναι (None, 28, 600).
Dropout Layer: Εφαρμόζεται μετά το πυκνό στρώμα για την αποφυγή της υπερπροσαρμογής.

Dense Layer: Έχει 128 νευρώνες και το σχήμα εξόδου είναι (None, 28, 128).
Dropout Layer: Εφαρμόζεται άλλο ένα στρώμα εγκατάλειψης, και πάλι για τον μετριασμό της υπερπροσαρμογής. Το σχήμα εξόδου παραμένει το ίδιο.

Flatten Layer: Μετατρέπει την είσοδο από ένα τρισδιάστατο σχήμα σε ένα δισδιάστατο σχήμα (None, 3584), vectorization.
Dense Layer: Έχει 10 νευρώνες, που αντιπροσωπεύουν τις 10 κλάσεις στο σύνολο δεδομένων MNIST. Το σχήμα εξόδου είναι (None, 10).
Ο συνολικός αριθμός των εκπαιδεύσιμων παραμέτρων του μοντέλου είναι 130.178.

Όσον αφορά την απόδοση του μοντέλου DNN, το έχετε εκπαιδεύσει χρησιμοποιώντας K-fold cross-validation, το οποίο υποδεικνύει ότι το μοντέλο εκπαιδεύτηκε και αξιολογήθηκε σε πολλαπλά υποσύνολα των δεδομένων. Κάθε επανάληψη χρησιμοποιεί μια διαφορετική αναδίπλωση ως σύνολο επικύρωσης, ενώ οι υπόλοιπες αναδιπλώσεις χρησιμοποιούνται για εκπαίδευση. Έχουν καταγραφεί οι μετρικές-metrics του training and validation (loss function, accuracy και AUC) για κάθε αναδίπλωση. Αξίζει να αναφερθεί ότι η απόδοση του μοντέλου αξιολογείται συνήθως με τη χρήση τέτοιων μετρικών, όπως ακόμα και, η ανάκληση και η βαθμολογία F1. Αυτές οι μετρικές παρέχουν πληροφορίες σχετικά με το πόσο καλά το μοντέλο είναι σε θέση να ταξινομήσει τα ψηφία στο σύνολο δεδομένων MNIST.



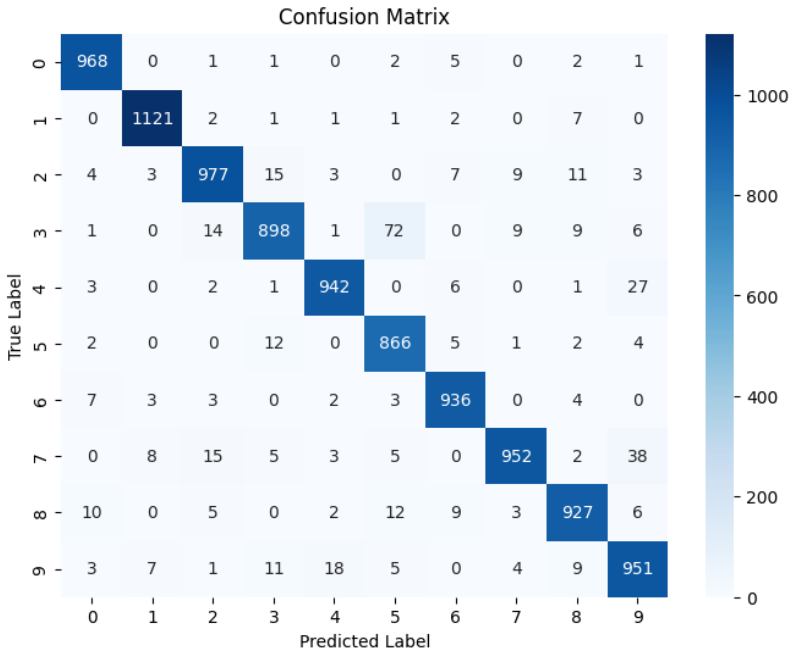
Αρχιτεκτονική του νευρωνικού δικτύου DNN.

Ακολουθεί ο τρόπος με τον οποίο λειτουργεί η διαδικασία εκπαίδευσης:

Ο κώδικας ξεκινά με την αρχικοποίηση μιας μεταβλητής fold σε 1, η οποία θα χρησιμοποιείται για την παρακολούθηση του τρέχοντος αριθμού fold. Τα δεδομένα εκπαίδευσης και επικύρωσης χωρίζονται σε K φορές χρησιμοποιώντας τη συνάρτηση kf.split(), η οποία λαμβάνει τα δεδομένα εκπαίδευσης (x_train και y_train) ως είσοδο. Η συνάρτηση kf.split() επιστρέφει τους δείκτες για τα δεδομένα εκπαίδευσης και επικύρωσης για κάθε fold. Σε κάθε επανάληψη του βρόχου for, εξάγονται οι δείκτες για την τρέχουσα αναδίπλωση. Τα δεδομένα εκπαίδευσης και επικύρωσης για την τρέχουσα αναδίπλωση (X_train_fold, y_train_fold, X_val_fold, y_val_fold) λαμβάνονται με τη δεικτοδότηση των αρχικών δεδομένων εκπαίδευσης χρησιμοποιώντας τους δείκτες αναδίπλωσης. Το μοντέλο (DNN) εκπαιδεύεται χρησιμοποιώντας τη συνάρτηση fit(). Τα δεδομένα εκπαίδευσης (X_train_fold και y_train_fold) περνούν ως είσοδοι. Τα δεδομένα επικύρωσης (X_val_fold και y_val_fold) παρέχονται χρησιμοποιώντας την παράμετρο validation_data. Η εκπαίδευση εκτελείται για έναν καθορισμένο αριθμό εποχών (50 σε αυτή την περίπτωση) και ένα μέγεθος batches 50. Η επανάκληση EarlyStopping χρησιμοποιείται για την παρακολούθηση της απώλειας και τη διακοπή της εκπαίδευσης εάν η απώλεια δεν βελτιωθεί για έναν ορισμένο αριθμό εποχών (υπομονή=2 σε αυτή την περίπτωση).

Αποθηκεύεται το ιστορικό εκπαίδευσης (history), το οποίο περιέχει πληροφορίες σχετικά με την απόδοση του μοντέλου (απώλεια, ακρίβεια κ.λπ.) κατά τη διάρκεια της εκπαίδευσης.

Technique	Set	Fold	Accuracy	Precision	Recall	F1 Score
DNN	Train	1	0.96408	0.96392137	0.96386	0.963844
DNN	Test	1	0.9588	0.95867468	0.958478	0.958532
DNN	Train	2	0.96424	0.9641491	0.963916	0.96394
DNN	Test	2	0.9567	0.95692065	0.956278	0.956423
DNN	Train	3	0.9639	0.96400473	0.963426	0.963634
DNN	Test	3	0.9589	0.959303	0.958307	0.958592
DNN	Train	4	0.96522	0.96499078	0.965159	0.964986
DNN	Test	4	0.9581	0.95782324	0.957809	0.957766
DNN	Train	5	0.96336	0.96379924	0.96284	0.963184
DNN	Test	5	0.9556	0.95584988	0.955097	0.955343
DNN	Train	6	0.96546	0.96570232	0.965025	0.965306
DNN	Test	6	0.9592	0.95964869	0.958715	0.959036



confusion matrix, δείχνει στην διαγώνιο όσα σωστά ταξινομήθηκαν ενώ στα υπόλοιπα στοιχεία την λάθος ταξινόμηση

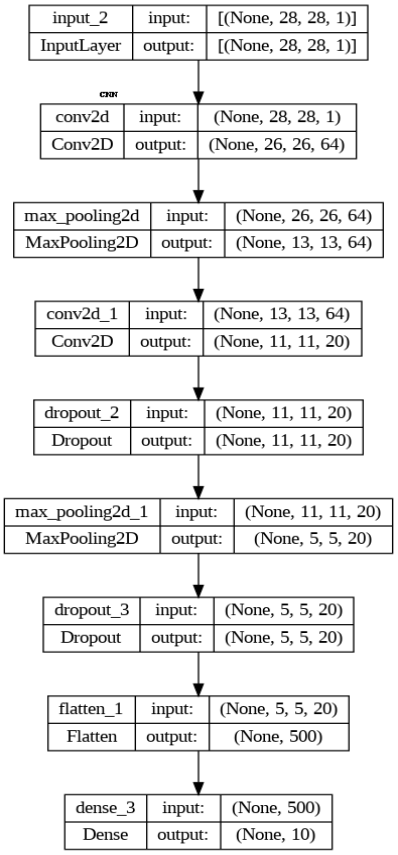
Απο τις καμπύλες που δημιουργήθηκαν για κάθε fold, για την ακρίβεια στο σύνολο των εποχών που τρέχει ο αλγόριθμος φαίνεται ότι η εκπαίδευση έχει θετικά αποτελέσματα και το δίκτυο μαθαίνει ομαλά και συνέχεια βελτιώνεται. δεν έχουν έντονες διακυμάνσεις και αναταραχές οι καμπύλες των train και validation μεταξύ τους. Αντίθετα, είναι θετικά τα αποτελέσματα και το μοντέλο εκπαιδεύεται επιτυχώς. Στη συνέχεια επιλέχθηκε μέσω των στατιστικών F1 score που εξήχθησε για το μοντέλο να ταξινομηθούν για να βρεθεί η πιο επιτυχημένη fold από τα 5 που διεξάχθηκαν. Τελικά, κρατάμε στη μνημη το index του εν λόγω fold και συνεχίζουμε με την εκπαίδευση του CNN δικτύου.

CNN Αρχιτεκτονική μοντέλου:
Παρακάτω περιγράφεται το μοντέλο συνελικτικού νευρωνικού δικτύου (CNN) που δημιουργήθηκε και εκπαιδεύεται σε δεδομένα εικόνας. Ακολουθεί μια ανάλυση της αρχιτεκτονικής του μοντέλου και της διαδικασίας εκπαίδευσης:

Το μοντέλο ορίζεται χρησιμοποιώντας το Sequential API της Keras, το οποίο σας επιτρέπει να δημιουργείτε μοντέλα στρώμα προς στρώμα.
Το μοντέλο αποτελείται από διάφορα στρώματα, συμπεριλαμβανομένων των επιπέδων συνελικτικής ανάλυσης (Conv2D), των επιπέδων μέγιστης συγκέντρωσης (MaxPooling2D), των επιπέδων εγκατάλειψης (Dropout) και ενός πλήρως συνδεδεμένου επιπέδου (Dense).
Το σχήμα εισόδου του μοντέλου είναι (28, 28, 1), υποδεικνύοντας ότι οι εικόνες εισόδου είναι εικόνες σε κλίμακα του γκρι με μέγεθος 28x28 εικονοστοιχεία.
Το σχήμα εξόδου του μοντέλου είναι (None, 10), υποδεικνύοντας ότι το μοντέλο προβλέπει πιθανότητες για 10 διαφορετικές κλάσεις.

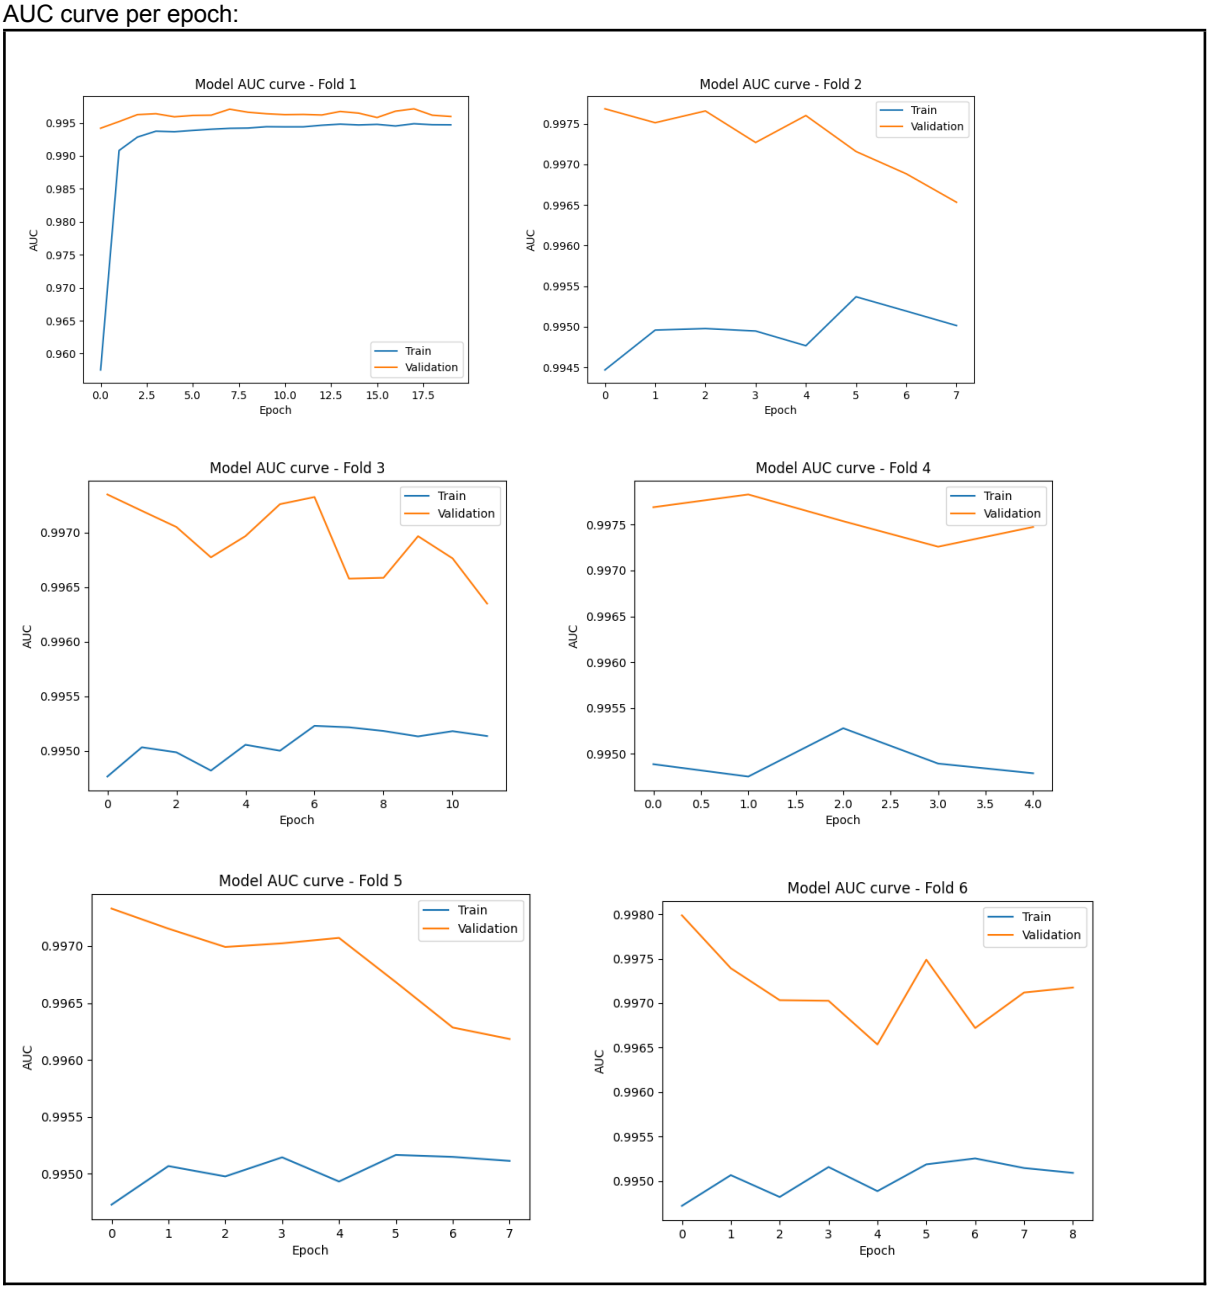
Η σύνοψη του μοντέλου δείχνει τον αριθμό των παραμέτρων σε κάθε στρώμα και τον συνολικό αριθμό των παραμέτρων του μοντέλου.

Η διαδικασία εκπαίδευσης χρησιμοποιεί τη διασταυρούμενη επικύρωση K-πτυχών, όπως αναφέρθηκε και στο DNN. Το μοντέλο εκπαιδεύεται χρησιμοποιώντας τη συνάρτηση fit(). Τα δεδομένα εισόδου (X_train_fold_cnn και y_train_fold_cnn) αναδιαμορφώνονται ώστε να ταιριάζουν με το σχήμα εισόδου του μοντέλου.
Τα δεδομένα εκπαίδευσης και τα δεδομένα επικύρωσης παρέχονται χρησιμοποιώντας την παράμετρο validation_data. Η εκπαίδευση εκτελείται για έναν καθορισμένο αριθμό εποχών (50 σε αυτή την περίπτωση) και ένα μέγεθος batches 50. Η επανάκληση EarlyStopping χρησιμοποιείται για την παρακολούθηση των απωλειών και τη διακοπή της εκπαίδευσης εάν οι απώλειες δεν βελτιωθούν για έναν ορισμένο αριθμό εποχών (υπομονή=2 σε αυτή την περίπτωση).
Μετά την εκπαίδευση, οι μετρικές αξιολόγησης (απώλεια, ακρίβεια, auc) εκτυπώνονται τόσο για τα σύνολα εκπαίδευσης όσο και για τα σύνολα επικύρωσης. Η αρχιτεκτονική του μοντέλου και η διαδικασία εκπαίδευσης που περιγράφηκε παραπάνω αποσκοπούν στην εκπαίδευση ενός μοντέλου CNN για την ταξινόμηση εικόνων κλίμακας του γκρι σε μία από τις 10 κλάσεις. Το μοντέλο χρησιμοποιεί στρώματα convolutional layers για την εξαγωγή χαρακτηριστικών από τις εικόνες, pooling layers για τη μείωση των χωρικών διαστάσεων, στρώματα διακοπής-dropout layers για την αποφυγή υπερπροσαρμογής και ένα πλήρως συνδεδεμένο στρώμα για την τελική ταξινόμηση. Η διαδικασία εκπαίδευσης χρησιμοποιεί K-fold cross-validation για την αξιολόγηση της απόδοσης του μοντέλου σε διαφορετικά υποσύνολα των δεδομένων εκπαίδευσης και την αποφυγή της υπερπροσαρμογής.

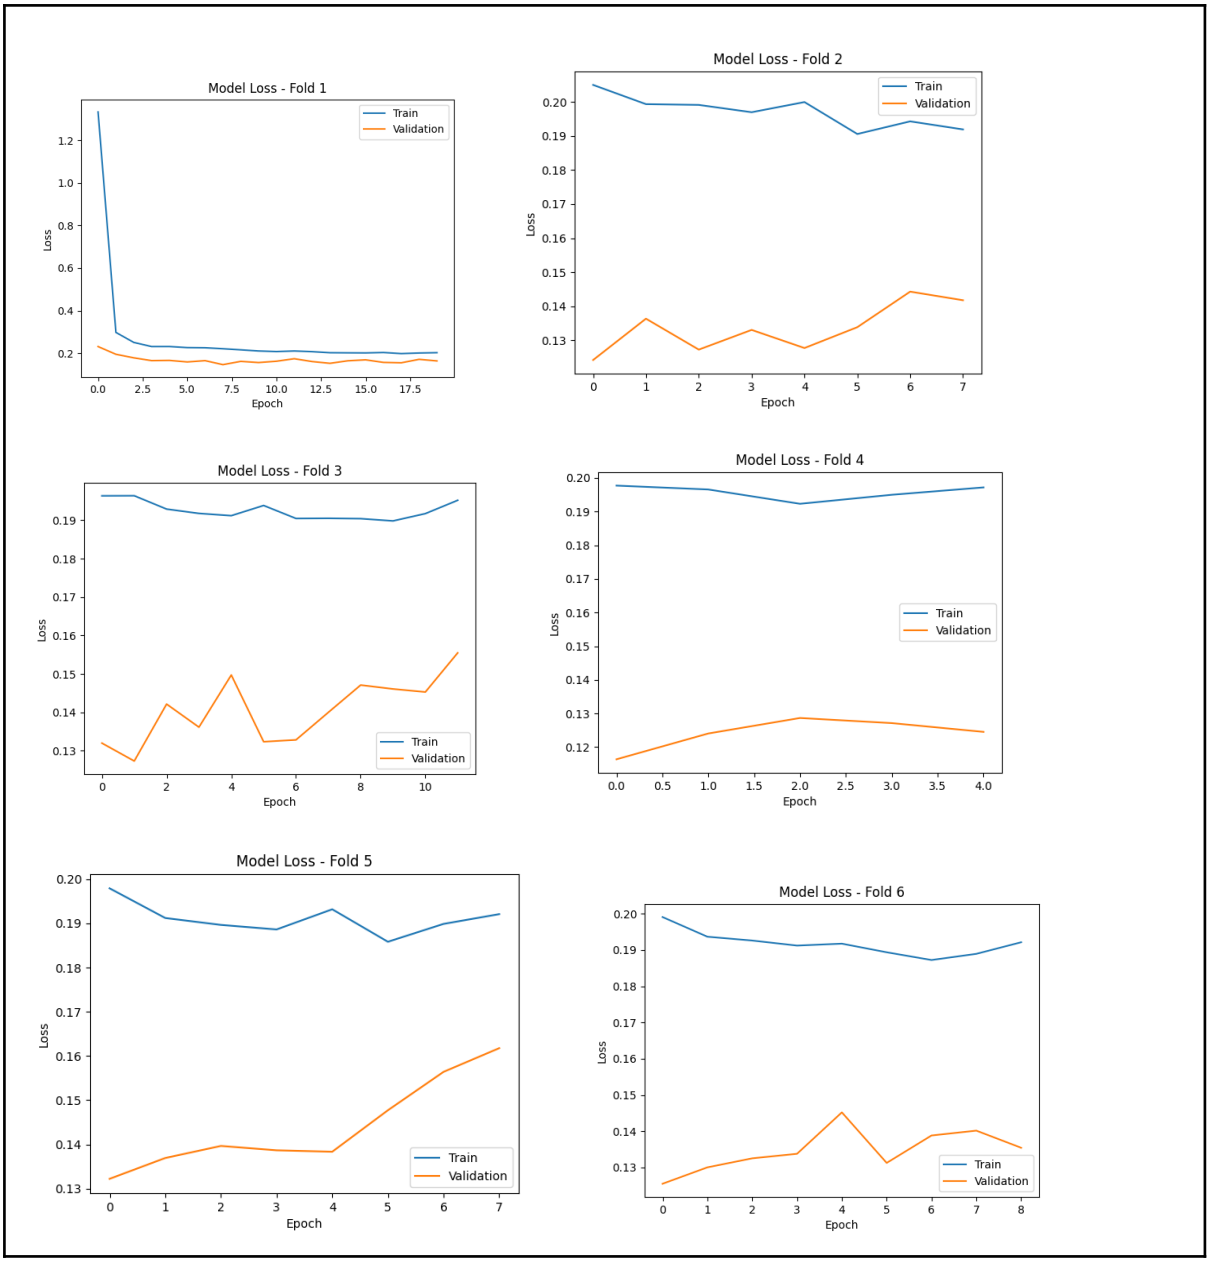


Αρχιτεκτονική του νευρωνικού δικτύου CNN.

AUC curve per epoch:



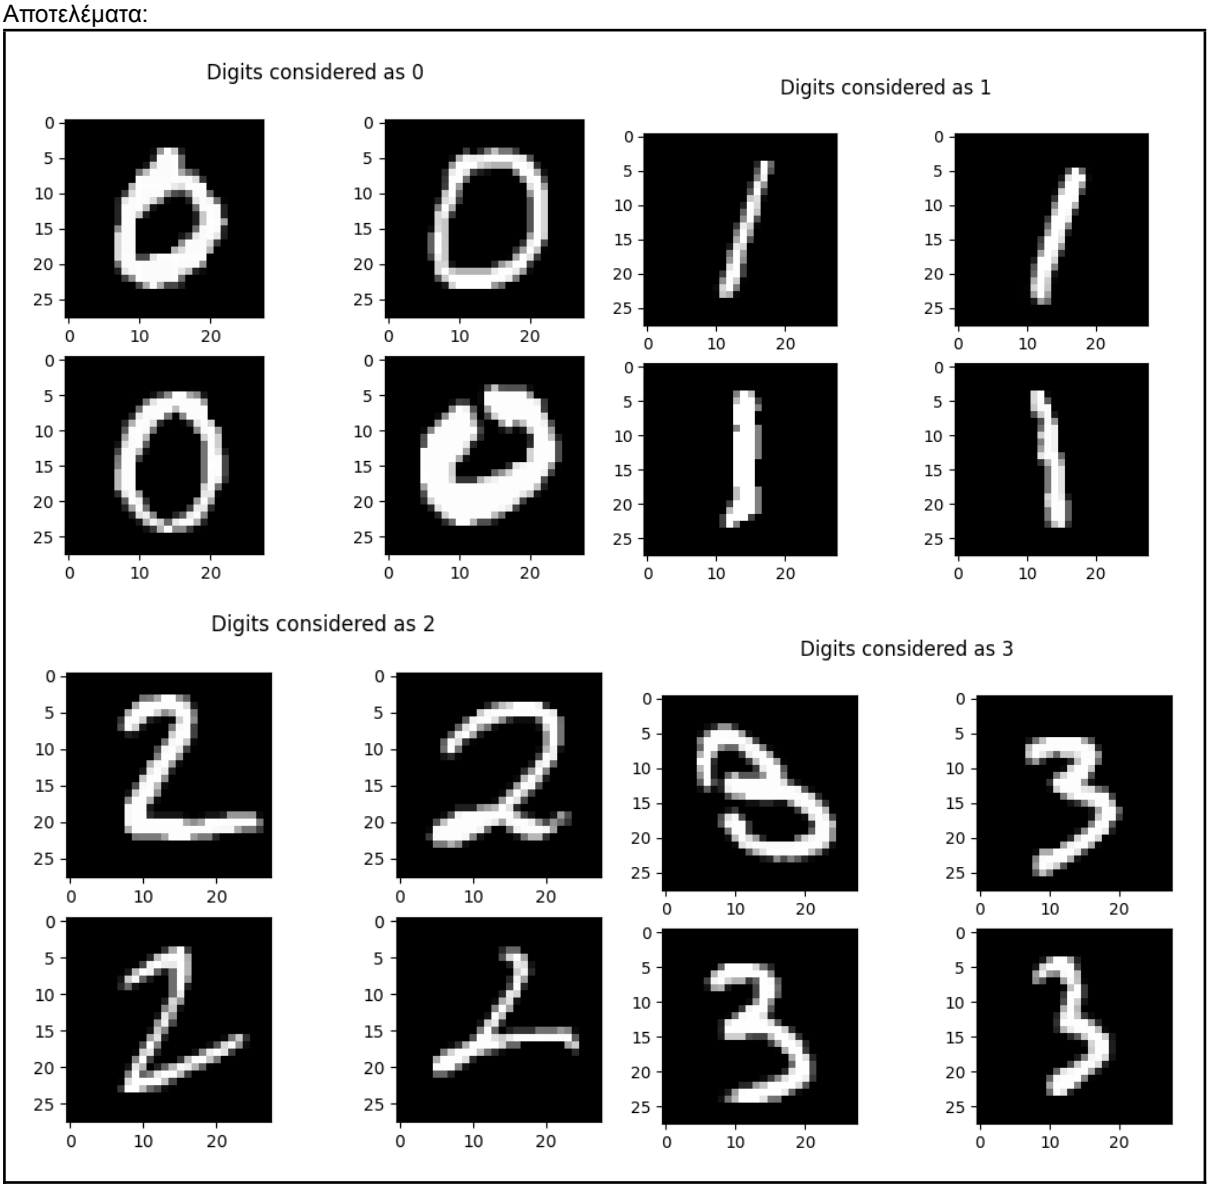
Loss Function per epoch:

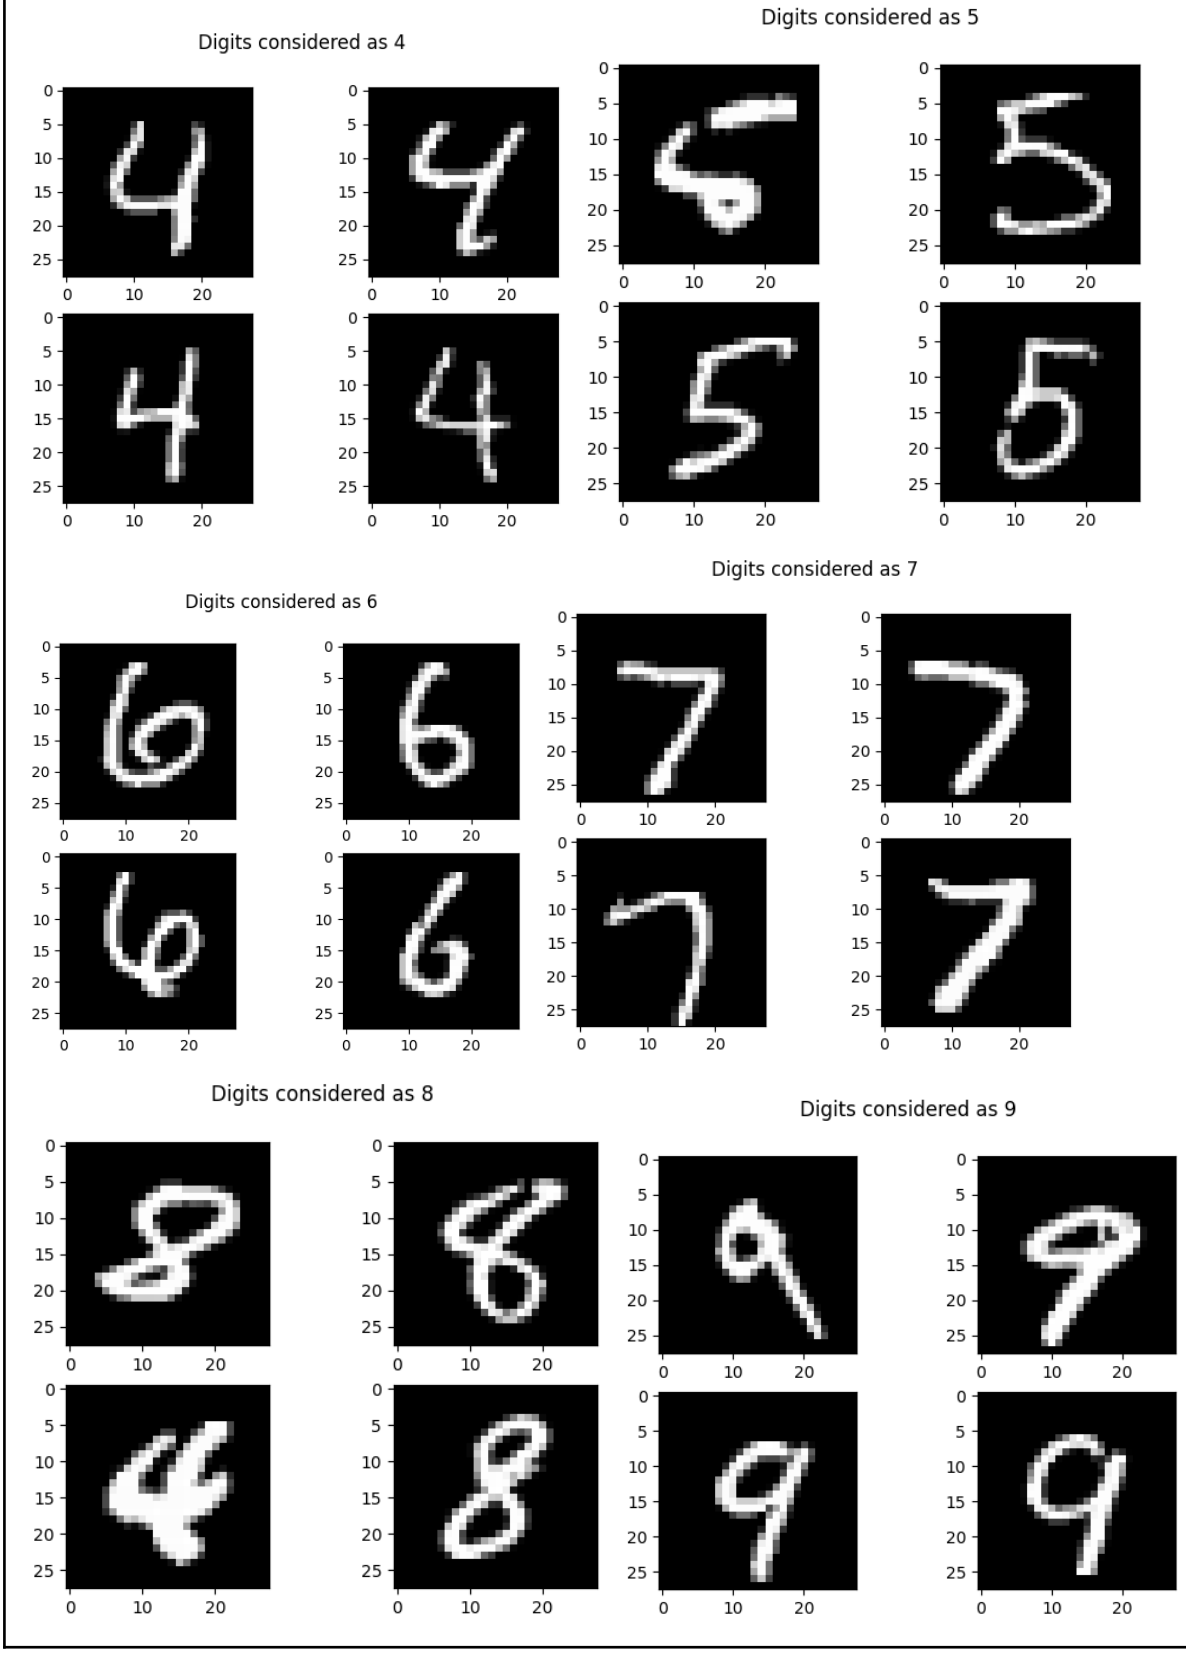


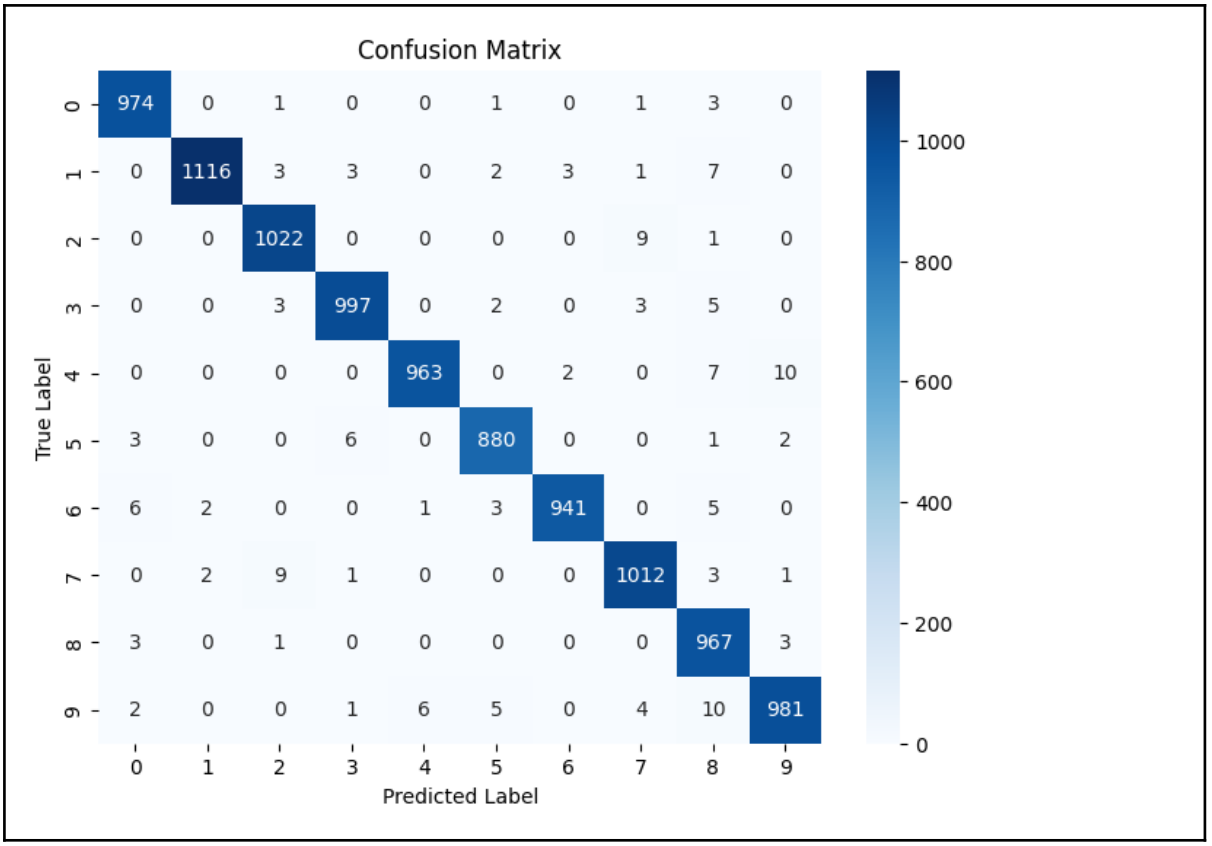
Technique	Set	Fold	Accuracy	Precision	Recall	F1 Score
CNN	Train	1	0.9495	0.95001926	0.949761	0.949415
CNN	Test	1	0.9525	0.95327428	0.952524	0.95226
CNN	Train	2	0.9637	0.96386137	0.963719	0.963582
CNN	Test	2	0.9655	0.96572735	0.965417	0.965311
CNN	Train	3	0.97176	0.972094398 2480416,	0.971628	0.971553
CNN	Test	3	0.9728	0.97315187	0.972754	0.972679
CNN	Train	4	0.97554	0.9757503	0.975366	0.975438
CNN	Test	4	0.9766	0.97681275	0.976478	0.976495

CNN	Train	5	0.98074	0.98092121	0.980655	0.980738
CNN	Test	5	0.9774	0.97766809	0.977186	0.977332
CNN	Train	6	0.98118	0.98129683	0.981064	0.981137
CNN	Test	6	0.9794	0.979461997 9590296,	0.979247	0.979319

Αποτελέματα:

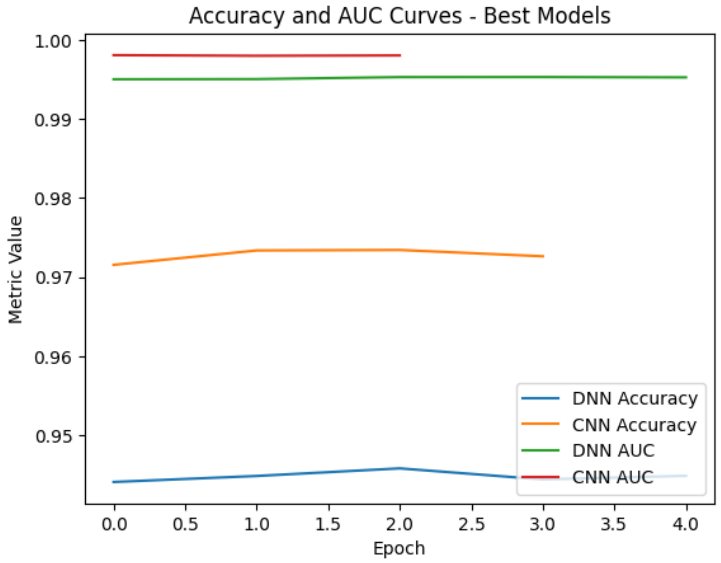



Digits considered as 4
Digits considered as 5
Digits considered as 6
Digits considered as 7
Digits considered as 8
Digits considered as 9



Οι καμπύλες που μετράνε την ακρίβεια δείχνουν επίσης υψηλή εκπαίδευση που κινείται σε πολύ ικανοποιητικά πείπεδα και φανέρα ακόμα καλύτερα από το DNN. Το γεγονός αυτό δικαιολογείται στη δομή των δικτυων αυτών, αφού στηρίζονται στην εξαγωγή χαρακτηριστικών από τις εικόνες.

Τέλος παράχθηκε το γράφημα στο οποίο παρουσιάζεται η ακρίβεια και οι καμπύλες AUC η επανάληψη k-fold κατά την οποία εμφανίζεται το καλύτερο μοντέλο για κάθε διαφορετικό είδος δικτύου. Στο σημείο αυτό αξίζει να αναφερθεί γιατί επιλέχθηκε να οπτικοποιηθεί η καμπύλη των AUC. Σύμφωνα με το γράφημα, το CNN έχει πολύ κλυτερη ακρίβεια αλλά ακόμα πιο σημαντικό η καμπύλη AUC βρίσκεται ακόμα πιο μακρυά από τη διαγώνιο.



Τελικά αποτελέσματα, τα καλύτερα μοντέλα και οι καμπύλες που δείχνουν την επιτυχία τους

Η απεικόνιση της καμπύλης AUC (Area Under the Curve) είναι απαραίτητη κατά τη σύγκριση διαφορετικών μοντέλων νευρωνικών δικτύων, επειδή παρέχει μια ολοκληρωμένη και διαισθητική απεικόνιση της απόδοσης του μοντέλου σε διαφορετικά κατώφλια ταξινόμησης. Η καμπύλη AUC δημιουργείται με την απεικόνιση του Ποσοστού Αληθώς Θετικών (Ευαισθησία) έναντι του Ποσοστού Ψευδώς Θετικών (1 - Ειδικότητα) σε διάφορα κατώφλια ταξινόμησης. Η τιμή AUC αντιπροσωπεύει τη συνολική απόδοση του μοντέλου στη διάκριση μεταξύ θετικών και αρνητικών δειγμάτων, ανεξάρτητα από το κατώφλι που έχει επιλεγεί. Μια υψηλότερη τιμή AUC υποδηλώνει καλύτερη ικανότητα διάκρισης και έναν αποτελεσματικότερο ταξινομητή. Ακολουθούν μερικοί λόγοι για τους οποίους η χάραξη της καμπύλης AUC είναι σημαντική κατά τη σύγκριση διαφορετικών μοντέλων νευρωνικών δικτύων. Συγκεκριμένα, προσφέρει μια πληρέστερη κατανόηση των δυνατοτήτων του μοντέλου πέραν της ακρίβειας και βοηθά στη λήψη τεκμηριωμένων αποφάσεων κατά την επιλογή του καλύτερου μοντέλου για μια δεδομένη εργασία.:

- ➢ Σύγκριση επιδόσεων: Η καμπύλη AUC επιτρέπει την άμεση οπτική σύγκριση μεταξύ διαφορετικών μοντέλων. Εξετάζοντας τις τιμές AUC και το σχήμα των καμπυλών, μπορείτε εύκολα να εντοπίσετε ποιο μοντέλο αποδίδει συνολικά καλύτερα.
- ➢ Ανεξαρτησία κατωφλίου: Σε αντίθεση με την ακρίβεια, η οποία εξαρτάται σε μεγάλο βαθμό από το επιλεγμένο κατώφλι, η καμπύλη AUC παρέχει μια ολοκληρωμένη αξιολόγηση της απόδοσης του μοντέλου σε όλα τα πιθανά κατώφλια. Αυτό την καθιστά ιδιαίτερα χρήσιμη όταν πρόκειται για ανισόρροπα σύνολα δεδομένων ή όταν το κόστος των ψευδώς θετικών και των ψευδώς αρνητικών είναι διαφορετικό.
- ➢ Ανταλλαγή ευαισθησίας-ειδικότητας: Η καμπύλη AUC απεικονίζει την ανταλλαγή μεταξύ της ευαισθησίας (αληθώς θετικό ποσοστό) και της ειδικότητας (αληθώς αρνητικό ποσοστό) του μοντέλου. Ανάλογα με την εφαρμογή, μπορεί να δώσετε προτεραιότητα στο ένα έναντι του άλλου. Η καμπύλη AUC βοηθά στην κατανόηση αυτού του συμβιβασμού και στην επιλογή του κατάλληλου κατωφλίου με βάση τις συγκεκριμένες ανάγκες σας.
- ➢ Ανθεκτικότητα του μοντέλου: Η καμπύλη AUC παρέχει πληροφορίες σχετικά με την ευρωστία των επιδόσεων του μοντέλου. Ένα μοντέλο με πιο ομαλή και απότομη καμπύλη είναι γενικά πιο ανθεκτικό και λιγότερο ευαίσθητο στις αλλαγές του κατωφλίου.
- ➢ Επιλογή μοντέλου: Κατά τη σύγκριση διαφορετικών μοντέλων νευρωνικών δικτύων, η καμπύλη AUC μπορεί να σας βοηθήσει να επιλέξετε το καταλληλότερο μοντέλο με βάση τη συνολική διακριτική του ικανότητα. Συγκρίνοντας τις καμπύλες, μπορείτε να εντοπίσετε τα μοντέλα που αποδίδουν σταθερά καλύτερα σε διάφορα κατώτατα όρια και να λάβετε μια τεκμηριωμένη απόφαση. Μάλιστα θα ήταν μία πολύ καλή ιδέα να πλοταριστούν σε ένα γράφημα οι καμπύλες όλων των cnn μεταξύ τους και όλων των dnn μεταξύ τουσ και να επιλεγεί και από το χρήστη οπτικά το μοντέλο που ειναι όσο το δυνατόν πιο μακρυά από τη διαγώνιο.

Συνεπώς αποδεικνύεται και έμπρακτα ότι για εικόνες ειναι καλύτερη η χρήση των CNN
Οι λόγοι για τους οποίους τα CNN προτιμώνται για εργασίες ταξινόμησης εικόνων είναι:

- ➢ **Εξαγωγή εντοπισμένων χαρακτηριστικών**: Οι CNNs είναι ειδικά σχεδιασμένοι για να καταγράφουν τις χωρικές και τοπικές εξαρτήσεις στις εικόνες. Χρησιμοποιούν συνελικτικά στρώματα που εφαρμόζουν φίλτρα σε μικρές τοπικές περιοχές της

εισόδου, επιτρέποντάς τους να συλλαμβάνουν τοπικά μοτίβα όπως ακμές, υφές και σχήματα. Αυτή η εξαγωγή τοπικών χαρακτηριστικών είναι κατάλληλη για εργασίες ανάλυσης εικόνων όπου η διάταξη των εικονοστοιχείων και οι τοπικές σχέσεις τους περιέχουν σημαντικές πληροφορίες.

- **Κοινή χρήση παραμέτρων:** Τα CNN αξιοποιούν τον διαμοιρασμό παραμέτρων, πράγμα που σημαίνει ότι το ίδιο σύνολο βαρών (φίλτρων) χρησιμοποιείται σε διαφορετικές χωρικές θέσεις της εικόνας εισόδου. Αυτό μειώνει σημαντικά τον αριθμό των παραμέτρων σε σύγκριση με τα πλήρως συνδεδεμένα DNN, καθιστώντας τα CNN πιο αποδοτικά και επεκτάσιμα για σύνολα δεδομένων εικόνας με μεγάλες διαστάσεις.
- **Μεταφραστικά αναλλοίωτοι:** Τα CNN παρουσιάζουν μεταφραστική αναλλοίωτη συμπεριφορά, δηλαδή μπορούν να αναγνωρίζουν μοτίβα ανεξάρτητα από τη θέση τους στην εικόνα. Αυτή η ιδιότητα είναι ζωτικής σημασίας για εργασίες ταξινόμησης εικόνων όπου η θέση ή ο προσανατολισμός του αντικειμένου εντός της εικόνας μπορεί να μεταβάλλεται. Τα DNN, από την άλλη πλευρά, δεν διαθέτουν μεταφραστική αναλλοίωτη ικανότητα, καθώς αντιμετωπίζουν κάθε εικονοστοιχείο ανεξάρτητα, γεγονός που τα καθιστά λιγότερο αποτελεσματικά στην καταγραφή χωρικών σχέσεων.
- **Ιεραρχική εξαγωγή χαρακτηριστικών:** Τα CNN αποτελούνται συνήθως από πολλαπλά επίπεδα συνελίξεων που ακολουθούνται από επίπεδα συγκέντρωσης, επιτρέποντάς τους να μαθαίνουν ιεραρχικές αναπαραστάσεις της εικόνας εισόδου. Τα πρώτα στρώματα συλλαμβάνουν χαρακτηριστικά χαμηλού επιπέδου, όπως ακμές και υφές, ενώ τα βαθύτερα στρώματα συλλαμβάνουν χαρακτηριστικά υψηλότερου επιπέδου και σημασιολογικές πληροφορίες. Αυτή η ιεραρχική εξαγωγή χαρακτηριστικών επιτρέπει στα CNN να μαθαίνουν σύνθετες αναπαραστάσεις και να συλλαμβάνουν σημαντικά μοτίβα σε διαφορετικά επίπεδα αφαίρεσης.
- **Μειωμένη υπερπροσαρμογή**: Τα CNN έχουν συχνά ένα φαινόμενο κανονικοποίησης λόγω των στρωμάτων συγκέντρωσης και των κοινών βαρών στα συνελικτικά στρώματα. Τα στρώματα συγκέντρωσης μειώνουν τις χωρικές διαστάσεις και παρέχουν μια μορφή χωρικής συνάθροισης, καθιστώντας το μοντέλο πιο ανθεκτικό σε μικρές μεταβολές στην είσοδο. Αυτό βοηθά στην αποφυγή της υπερπροσαρμογής, ιδίως σε σύνολα δεδομένων με περιορισμένα δείγματα εκπαίδευσης όπως το MNIST.
- **Αποτελεσματική εκμάθηση παραμέτρων**: Τα CNN μπορούν να εκμεταλλευτούν τις τοπικές συσχετίσεις στα δεδομένα εισόδου, επιτρέποντάς τους να μαθαίνουν σύνθετες αναπαραστάσεις με λιγότερες παραμέτρους. Αυτή η αποτελεσματικότητα καθιστά τα CNN κατάλληλα για σύνολα δεδομένων εικόνας μεγάλης κλίμακας και τους επιτρέπει να επιτυγχάνουν υψηλότερη ακρίβεια με μικρότερο αριθμό παραμέτρων σε σύγκριση με τα πλήρως συνδεδεμένα DNN.

Συνολικά, ο εγγενής σχεδιασμός και οι ιδιότητες των CNNs τα καθιστούν καταλληλότερα για εργασίες ταξινόμησης εικόνων, όπως η MNIST. Μπορούν να συλλάβουν αποτελεσματικά τα τοπικά μοτίβα, να αξιοποιήσουν τον διαμοιρασμό παραμέτρων, να παρουσιάσουν μεταφραστική αμεταβλητότητα, να εκτελέσουν ιεραρχική εξαγωγή χαρακτηριστικών, να μειώσουν την υπερπροσαρμογή και να μάθουν αποτελεσματικές αναπαραστάσεις. Ενώ τα DNN μπορούν ακόμη να εφαρμοστούν σε σύνολα δεδομένων εικόνας, τα CNN έχουν επιδείξει ανώτερες επιδόσεις και έχουν γίνει η πρώτη επιλογή για εργασίες που σχετίζονται με εικόνες.