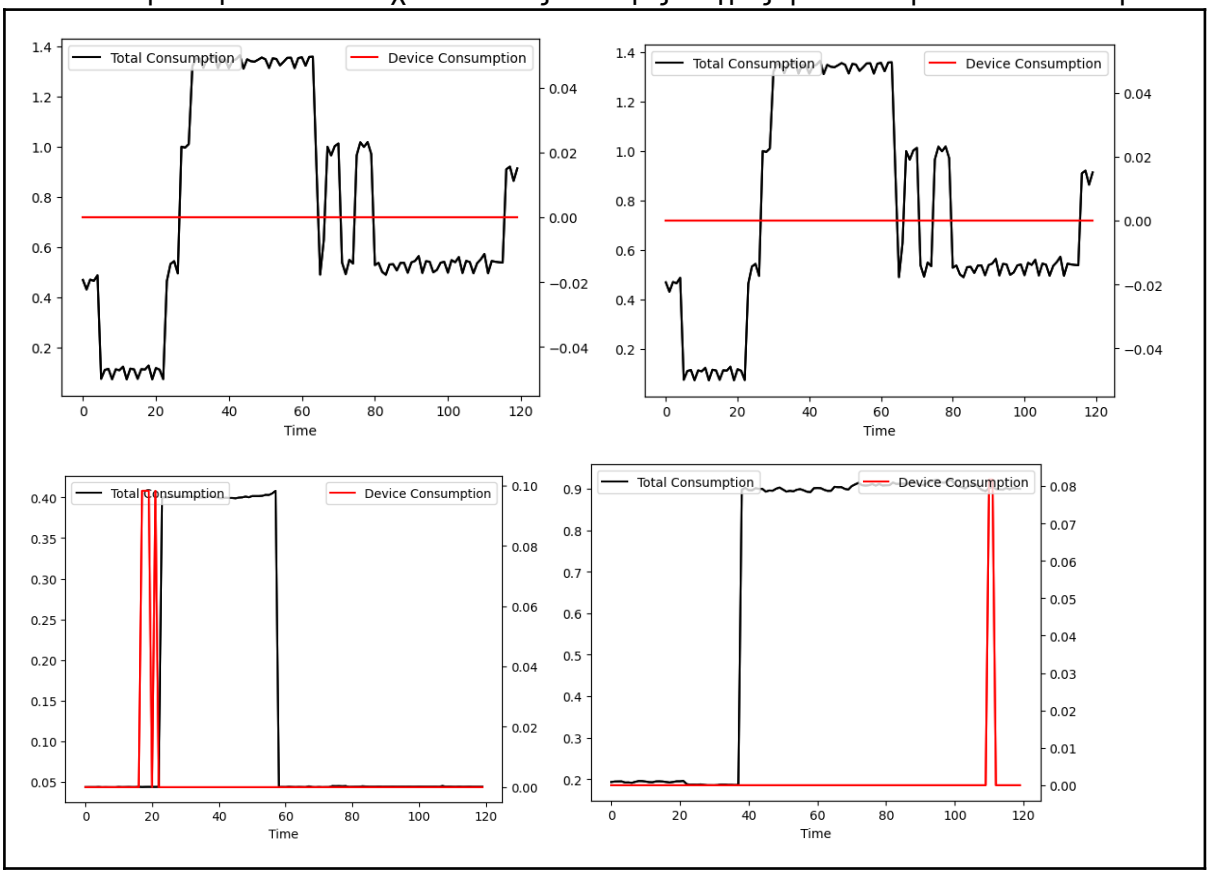
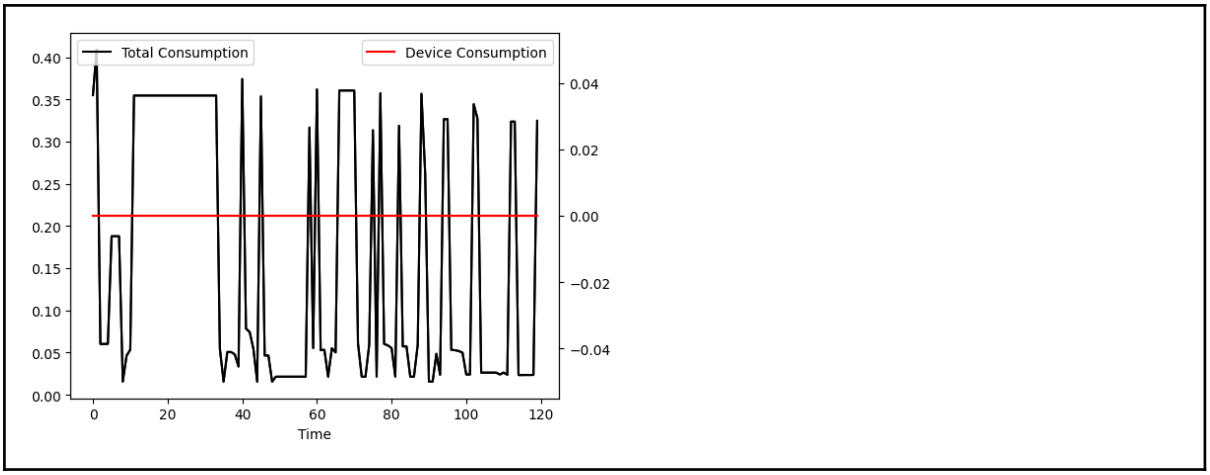
Τεχνική Έκθεση Comparing RNN-architectures
Μαρία Μελίνα Δολαψάκη

Στο τρίτο μέρος της εργασίας ζητείται να προβλεφθεί η συμπεριφορά μίας καφετιέρας, αφού εκπαιδευτεί σε δεδομένα ακολουθιών διάρκειας 2ωρών- 120 λεπτών. Τα δεδομένα που δόθηκαν στα ακολουθιακά μοντέλα εκπαίδευσης είναι η συνολική κατανάλωση του νοικοκυριού, καθώς και η αντίστοιχη κατάνάλωση της συσκευής για κάθε στιγμή μέτρησης. Στόχος είναι να προβλεφθεί από το μοντέλο η κατανάλωση της συσκευής σε Watt, δηλαδή η έξοδος της πρόβλεψης να αναφέρονται στην καφετιέρα.

Δίνονται σε τρεις τυχαίες χρονικές στιγμές γραφήματα που δείχνουν τη συσκευή και τη συνολική κατανάλωση του νοικοκυριού. Τα γραφήματα έχουν 2 άξονες κατά x, δεξιά και αριστερά του γραφήματος, που αναφέρονται αντίστοιχα στη μετρητική μονάδα της συνολικής κατανάλωσης του νοικοκυριού και στην μετρητική μονάδα μέτρησης της καφετιέρας. Ο άξονας y αναφέρεται σε κάθε ένα λεπτό εκ των 120 για τα οποία έχουμε μετρήσεις. Εικ1, Εικ.2 και Εικ3. φαίνεται ότι οι μετρήσεις της καφετιέρας έχουν ακρίβεια στα ψηφία του 2ου δεκαδικού, άρα και πολύ μεγαλύτερη πρέπει και να είναι η ακρίβεια και το σφάλμα στην εκπαίδευση των μοντέλων. Τυχαίνει και τις τέσσερις στιγμές η συσκευή να είναι κλειστή.

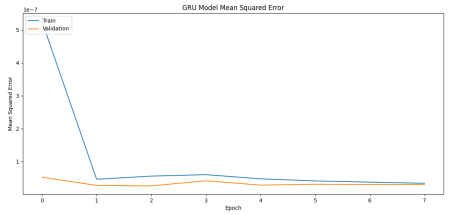


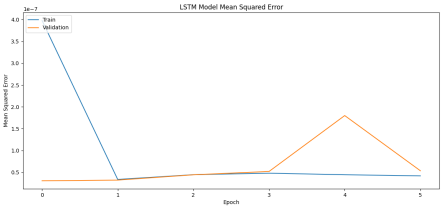


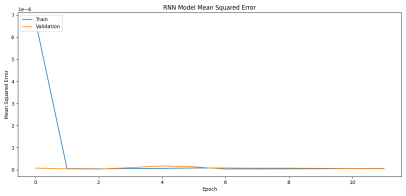
Γύρω στο 0.08-0.10 είναι η τιμή της κατανάλωσης για τα 3-5 λεπτά που μένει ανοιχτή ηη συσκευή μέσα στο διάστημα των 120 λεπτών, όπως αναφέραμε το μέγεθος είναι της τάξης του 10^-2 σε σχέση με το αντίστοιχο της συνολικής που είναι γύρω στο 0.9 της τάξης του 10^-1. Αντίθετα, τις στιγμές που η συσκευή είναι κλειστή η συνολική κατανάλωση μπορεί ακανόνιστα να κινείται σε διαφορετικές τιμές. Φαίνεται ότι η εκπαίδευση είναι αδύνατη αν δεν κανονικοποιηθούν τα δεδομένα, για τη διαδικασία αυτή έχουμε στα δεδομένα τη max τιμή κατανάλωσης Total Consuption & max της Device Concuption. Μας δίνεται η δυνατότητα έτσι να κανονικοποιήσουμε τα δεδομένα αλλά και να πραγματοποιήσουμε και απο-κανονικοποίηση στα δεδομένα, μετα το πέρας της εκπαίδευσης.

Αφού, τα δεδομένα είναι Sequential και θέλουμε πρόβλεψη για μία νέα χρονική στιγμή είναι προφανές ότι τα μοντέλα που χρησιμοποιούνται για αυτές τις διαδικασίες είναι τα RNN και LSTM μοντέλα. Βιβλιογραφικά αναφέρεται ότι αρχικά αναπτύχθηκε η αρχιτεκτονική των RNN, αλλά για να αντιμετωπιστούν κάποια προβλήματα στην εκπαίδευσή τους εξελίχθηκαν τα LSTM & GRU μοντέλα που φαίνεται να έχουν καλύτερη συμπεριφορά στη πρόβλεψη ακολουθιών. Τέτοιες ακολουθίες μπορεί ακόμα να είναι και στο NLP η πρόβλεψη επόμενου χαρακτήρα ή ακόμα και λέξης για τη παραγωγή νέου κειμένου. Τα δεδομένα εισόδου και εξόδου δίνονται για το χωρισμό των στοιχείων σε train set & test set. Αφού κατασκευάστηκαν τα 3 μοντέλα που ζητήθηκαν, προστέθηκε ένα κρυφό στρώμα, έγιναν Compile με τη χρήση του Adam, ώστε να διατηρηθούν τα αποτελέσματα με θετικό πρόσημο. Έτσι, δύναται η έξοδος να είναι πολλαπλών στοιχείων σε αντίθεση με την περίπτωση χρήσης της Softmax, που αυτό δεν το επιτρέπει.

Θα γίνει η απόπειρα μίας τέτοιας εκπαίδευσης. Έπειτα η πρόβλεψη των τιμών εξόδου γίνεται μετά τη διαδικασία denormalize των training data και της εξόδου που παράγεται από την πρόβλεψη. Τα αποτελέσματα της εκπαίδευσης για τις εποχές που τέθηκαν και το early stopping παράμετρο (`EarlyStopping(monitor='val_loss', patience=5)`) οπτικοποιούνται στα γραφήματα RMSE-epochs για κάθε ένα μοντέλο εκπαίδευσης.

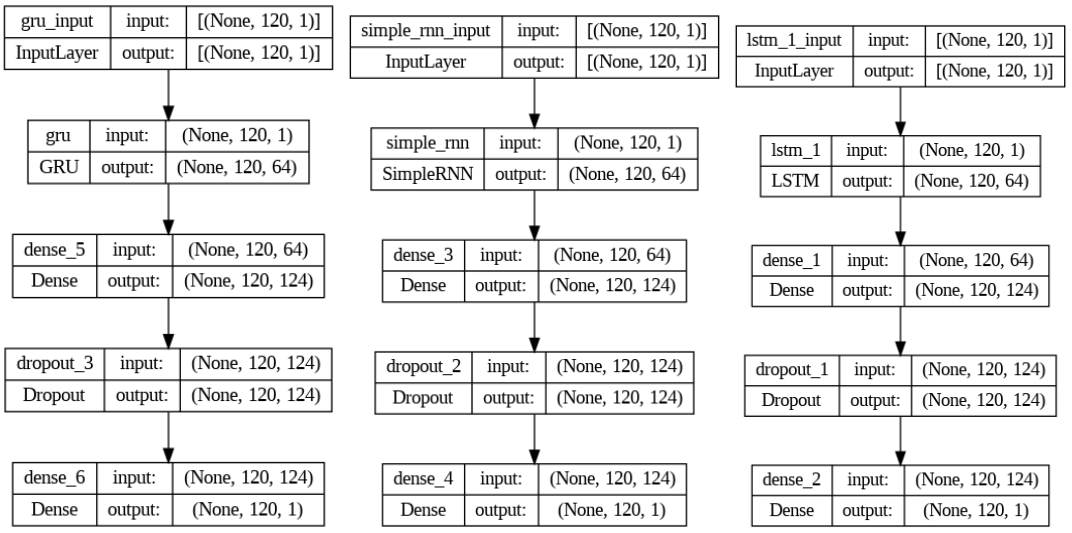


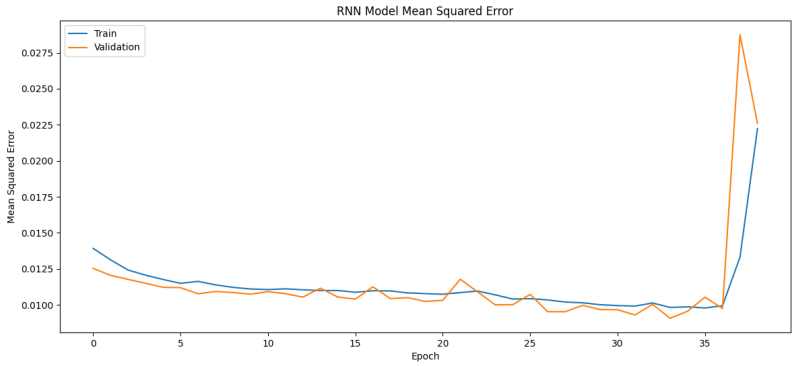


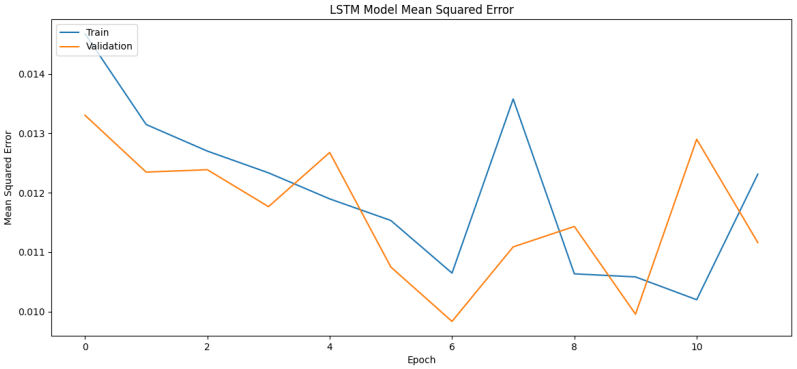


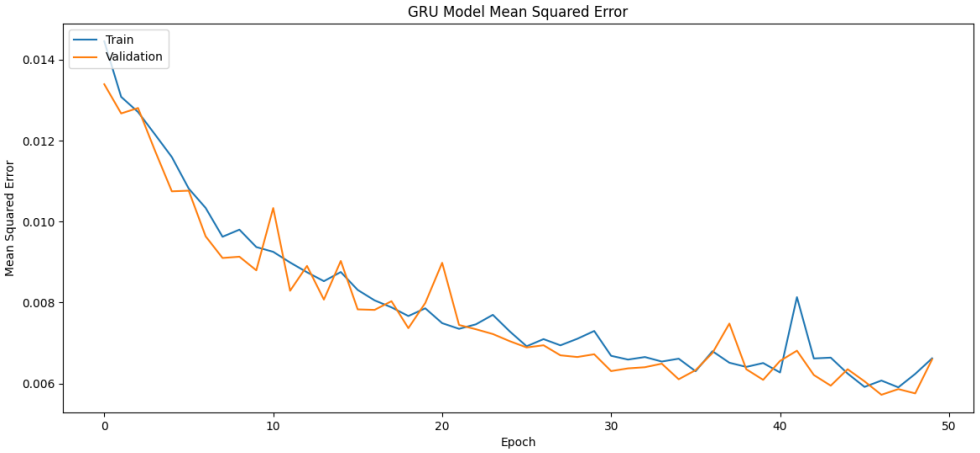
Εδώ παρουσιάζονται τα δεδομένα πριν διορθωθεί η εκφώνηση, δηλαδή όλα τα δεδομένα έχουν δοθεί σε λάθος μονάδα μέτρησης. Πλέον μετά τη διόρθωση τα αποτελέσματα είναι στον παρακάτω πίνακα.

Τα 3 μοντελα :



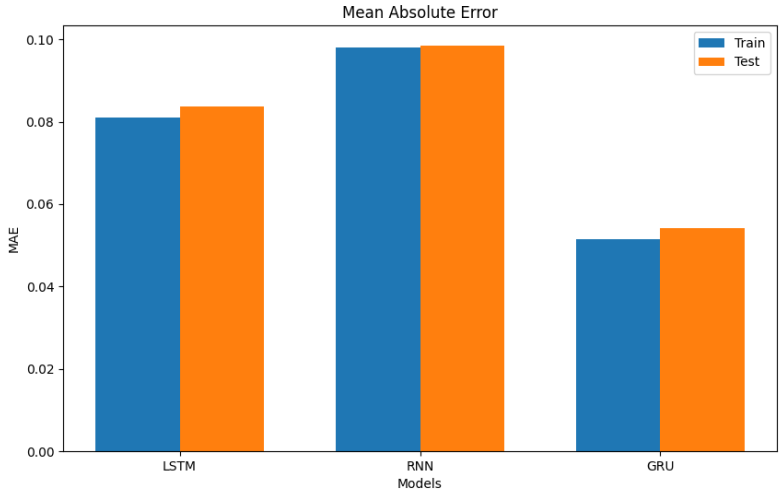




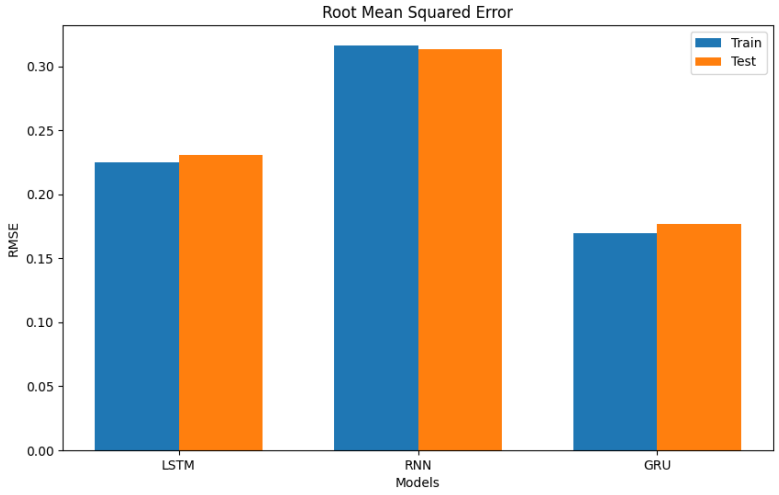


Τα μοντέλα που χρησιμοποιήθηκαν φαίνεται ότι καταφέρνουν, αν και όχι τόσο ομαλά και εκπαιδεύονται, μιας και μειώνεται το μέσο απόλυτο σφάλμα, σε ικανοποιητικά επίπεδα. Βέβαια η max τιμή δεν είναι η πραγματική max τιμή για τις ακολουθίες που δόθηκαν, αφού αν ψάξουμε το max value είναι διαφορετικό από το δοθέν της εκφώνησης. Άρα δεν κανονινκοποιήθηκαν τα δεδομένα στην κλίμακα του 0-1 ώστε αυτά εδώ τα μεγέθη μετρητικά να σημαίνουν κάτι ιδιαίτερο. Παρόλ'αυτά το σφάλμα μειώνεται και αντίστοιχη τάση παρακολουθείται και στο validation set αν και η καμπύλη του δεν είναι διόλου ομαλή. Αποτέλεσμα αυτού είναι το overfitting- underfitting στα δεδομένα που παρουσιάστηκαν στα μοντέλα. Αν υπήρχε διαθέσιμος χρόνος θα είχε γίνει αρκετή έρευνα για την εύρεση της κατάλληλης αρχιτεκτονικής. Επειδή όμως δεν υπήρχε εκ μέρους μου επαρκής χρόνος, η επίλυση έχει στόχο το πρόβλημα να βγάζει αποτελέσματα. Επειδή μετά από πολλές μέρες απλά χαίρομαι που απλά τα αποτελέσματά μου δεν είναι μόνο μία ευθεία γραμμή, όπως και χωρίς τη διόρθωση κλίμακας (kW-W) των στοιχείων της εκφώνησης.

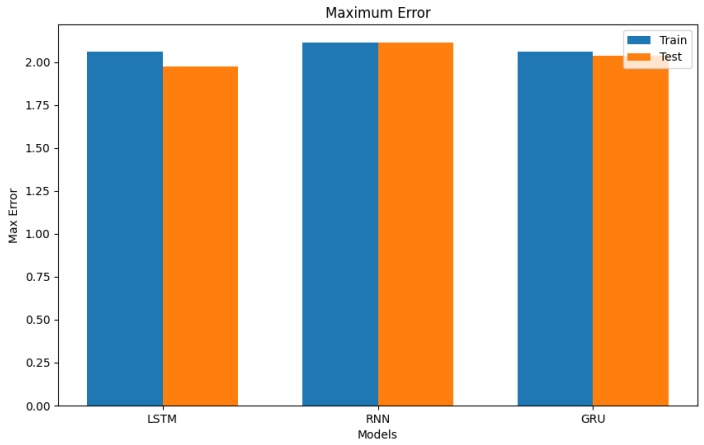
Μαζί παράχθηκαν boxplots που δείχνουν το RMSE, Mean Absolute Error & Max Error μετά την κανονικοποίηση.



Το MAE έχει πολύ καλή τιμή και μάλιστα είναι το χαμηλότερο από όλα τα άλλα μέτρα. Μόνο του όμως δεν περιγράφει την κατάσταση εκπαίδευσης. Σε συνδυασμό με τα υπόλοιπα μέτρα μέτρησης της ακρίβειας αποκτούμε μια καλύτερη εικόνα. Τα RNN όντως περιμένουμε να έχει χαμηλότερη ακρίβεια, συγκριτικά με τα άλλα μοντέλα

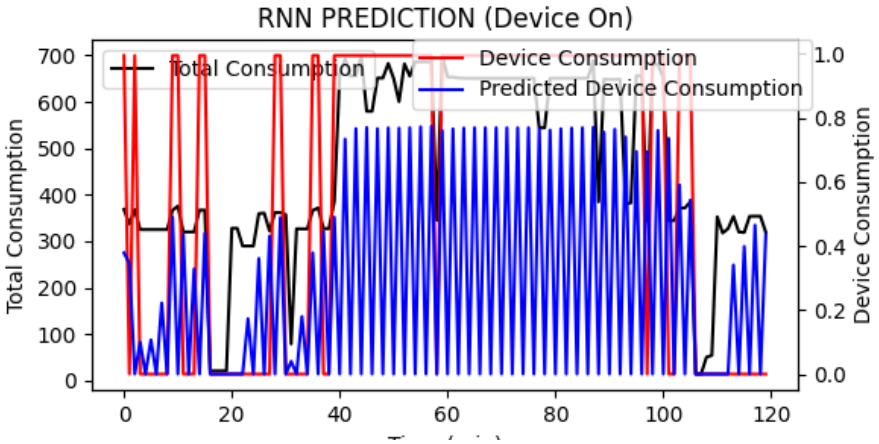


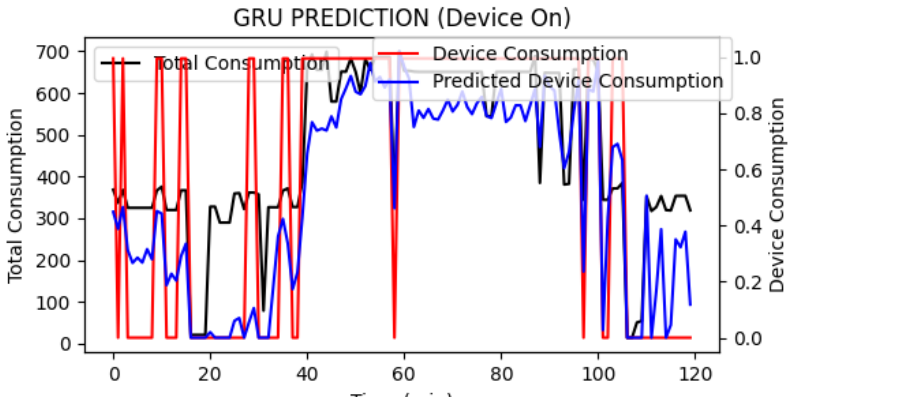
Το μοντέλο του GRU έχει την καλύτερη ακρίβεια τετραγωνικού σφάλματος, γεγονός αναμενόμενο. Θεωρούνται αρκετά καλά αποτελέσματα.

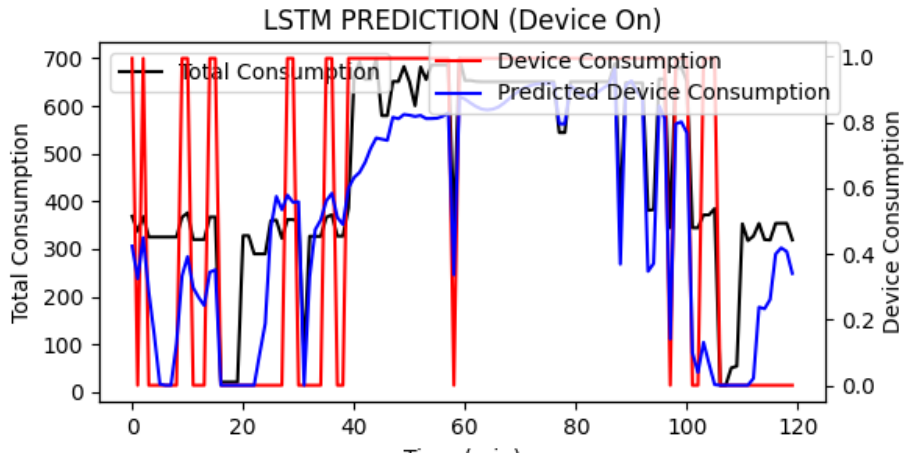


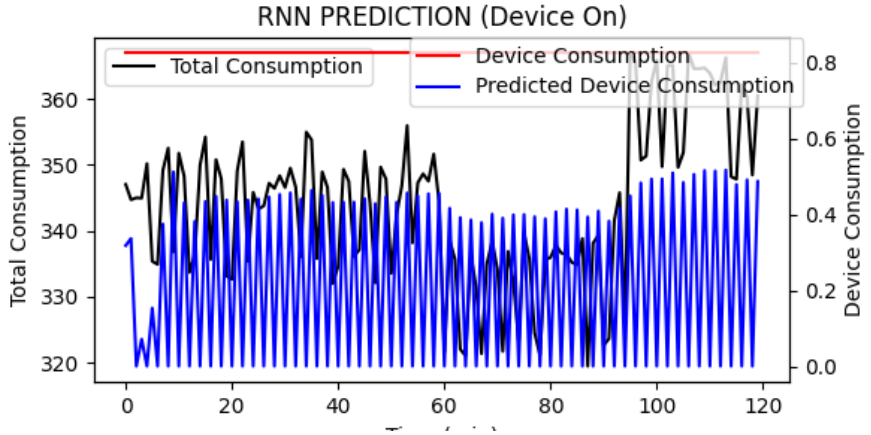
Το max error δείχνει ότι μερικές φορές ενώ η συσκευή είναι ανοιχτή, αυτό δεν ανιχνεύεται. Το μέγιστο error θεωρείται μεγάλο σε σχέση με τα δεδομένα του προβλήματος.

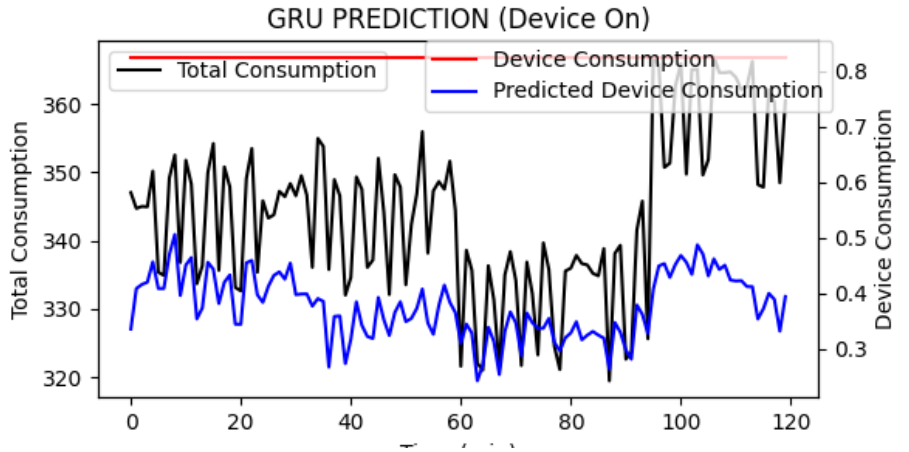
Τελικά, η πρόβλεπόμενες τιμές καταναλώσης της συσκευής θα αξιολογηθούν και για τις 2 περιπτώσεις που η συσκευή είναι αναμμένη και 2 περιπτώσεις που θα είναι κλειστή. Στο γράφημα έχουν ταυτόχρονα εμφανιστεί η καμπύλες Total Consumption , στα δεξιά και η ακολουθία της καφετιέρας και η Predicted Consumption, στα αριστερά του γραφήματος. Τα αποτελέσματα φαίνεται να μην είναι ικανοποιητικά αλλά είναι μία καλή αρχή. Η συσκευή όταν είναι ανοιχτή προβλέπεται αρκετές φορά τιμή κοντά στην πραγματική κατανάλωση. Αν όμως η συσκευή είναι κλειστή, παρατηρείται στα αποτελέσματα μία τάση οι προβλεπόμενες τιμές να συνεχίζουν να μιμούνταιι το Total Consumption. Είναι αναγκαία η χρήση περισσότερων στρωμάτων και προσαρμογή στον αριθμό των batches.

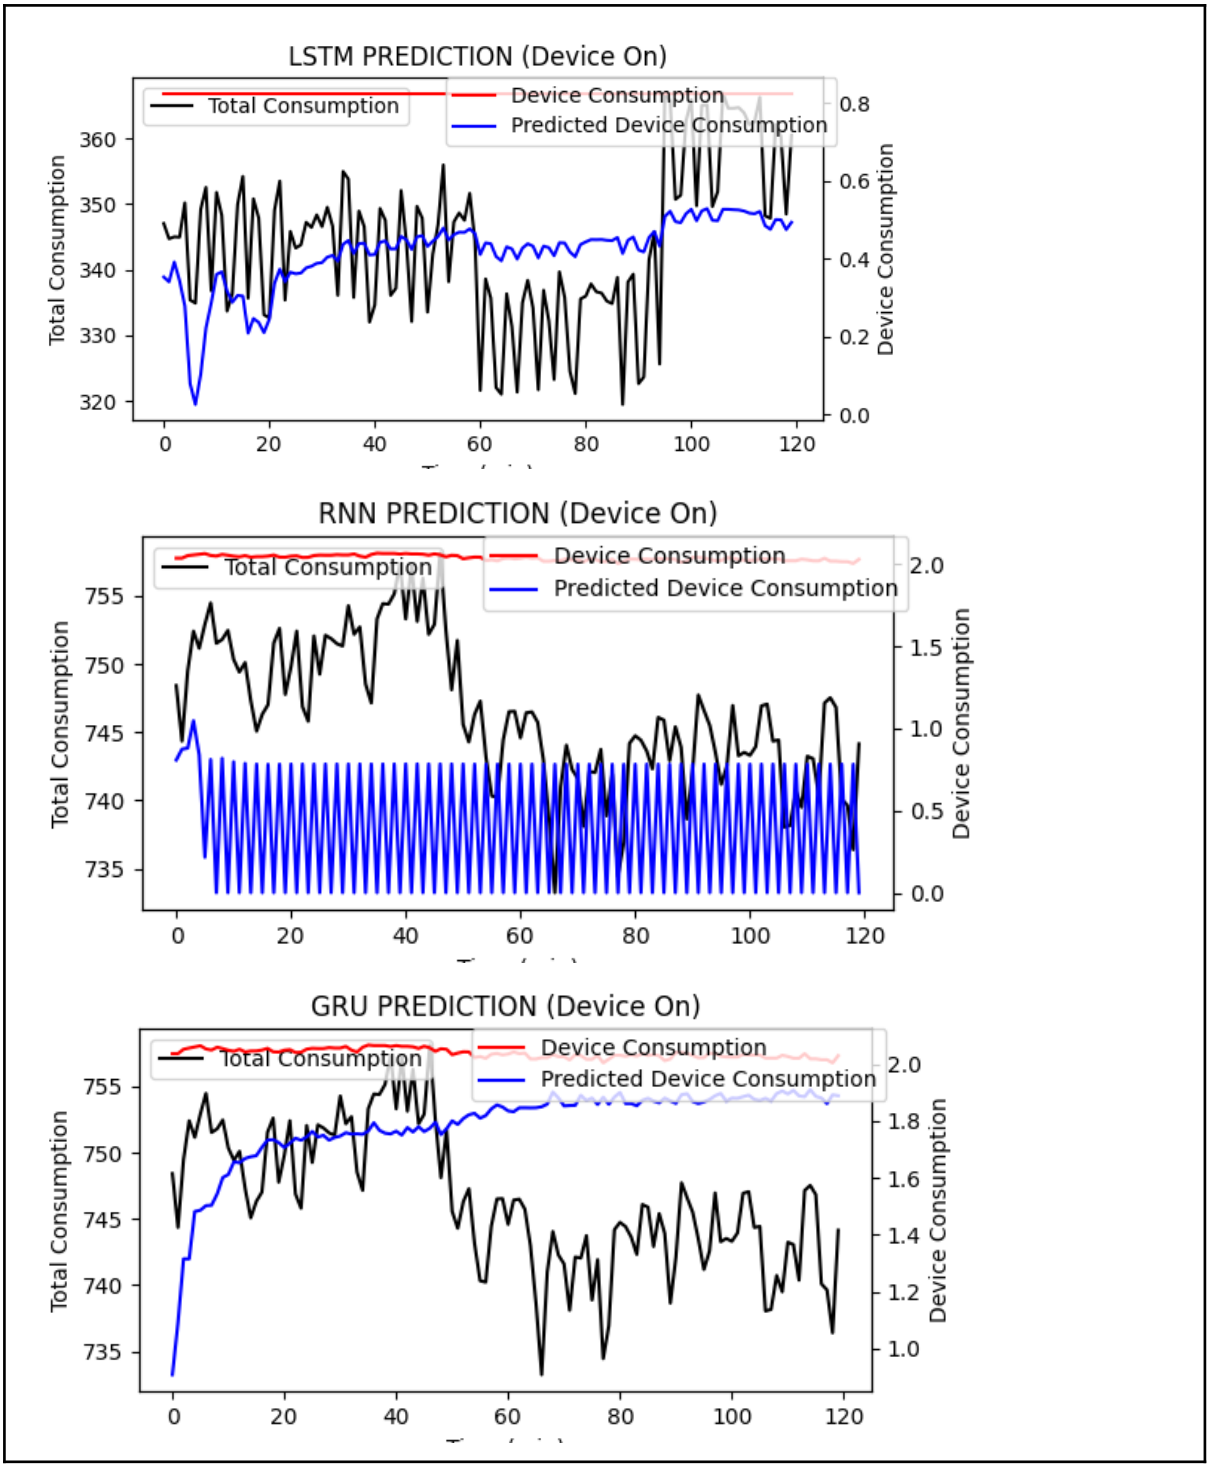


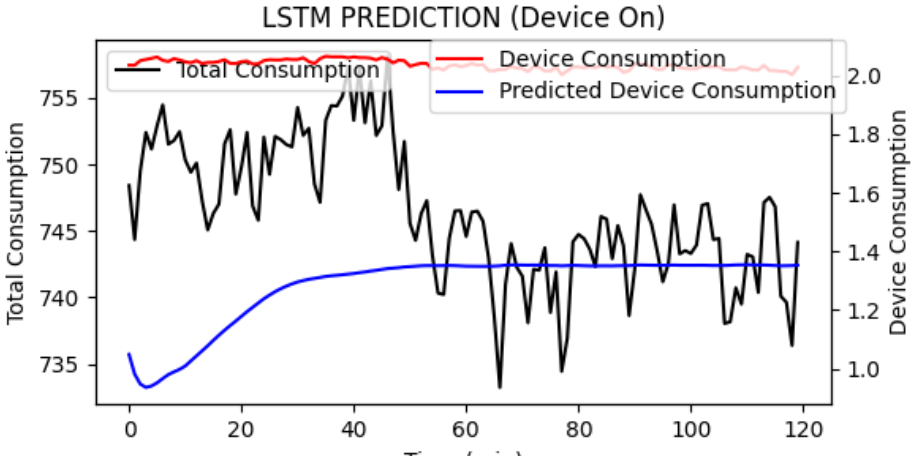

GRU PREDICTION (Device On)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption
Device Consumption

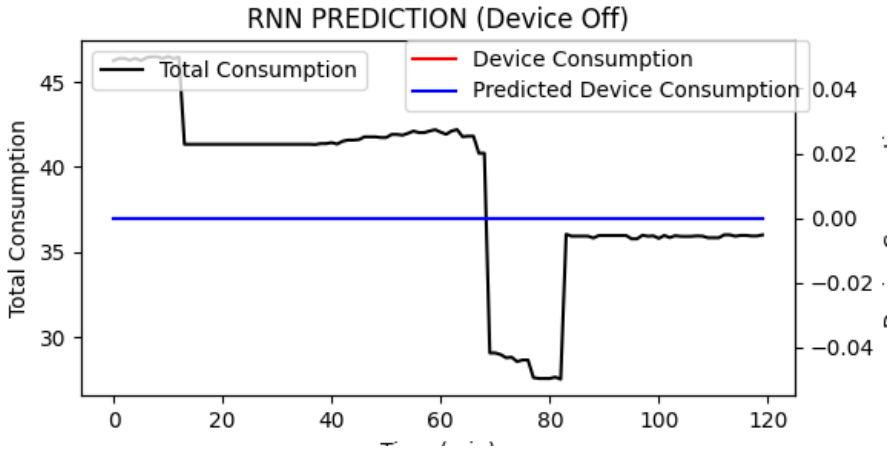

LSTM PREDICTION (Device On)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption
Device Consumption

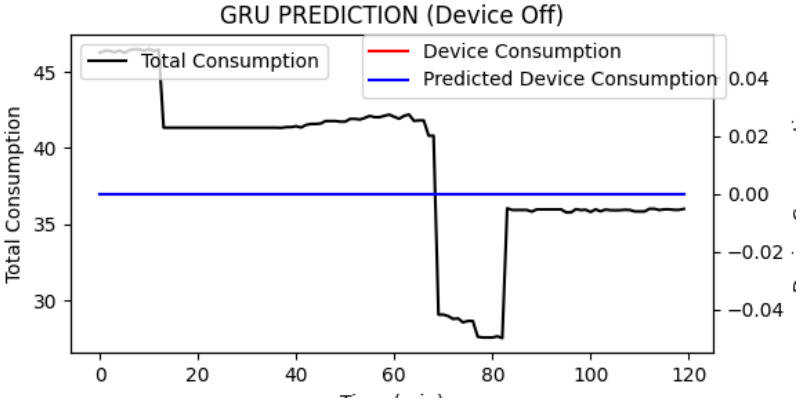

RNN PREDICTION (Device On)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption
Device Consumption

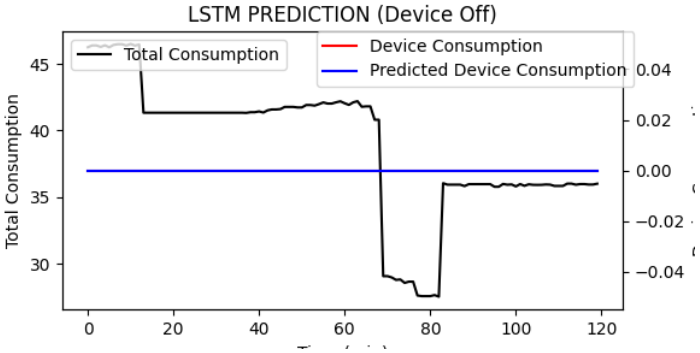

GRU PREDICTION (Device On)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption
Device Consumption

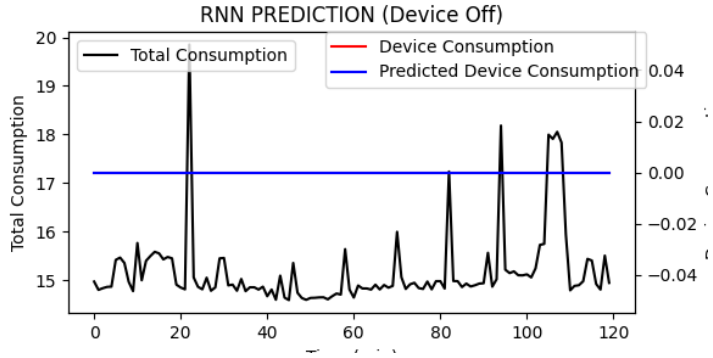

LSTM PREDICTION (Device On)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption
Device Consumption
RNN PREDICTION (Device On)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption
Device Consumption
GRU PREDICTION (Device On)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption
Device Consumption

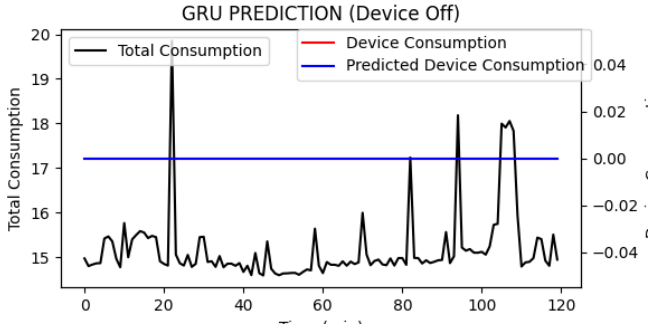

LSTM PREDICTION (Device On)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption
Device Consumption
755
750
745
740
735
2.0
1.8
1.6
1.4
1.2
1.0
0
20
40
60
80
100
120

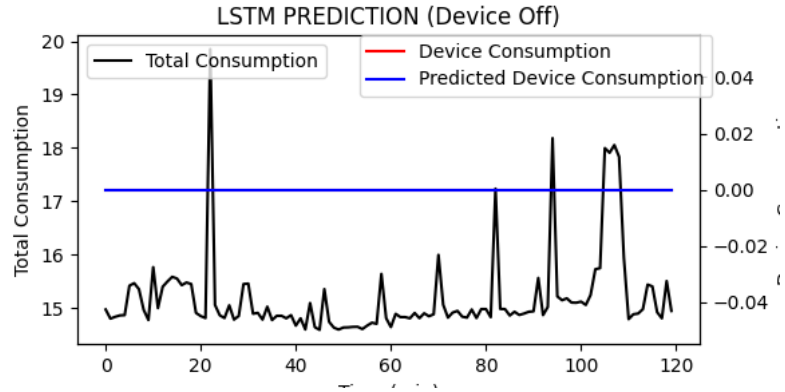

RNN PREDICTION (Device Off)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption
45
40
35
30
0.04
0.02
0.00
−0.02
−0.04
0
20
40
60
80
100
120

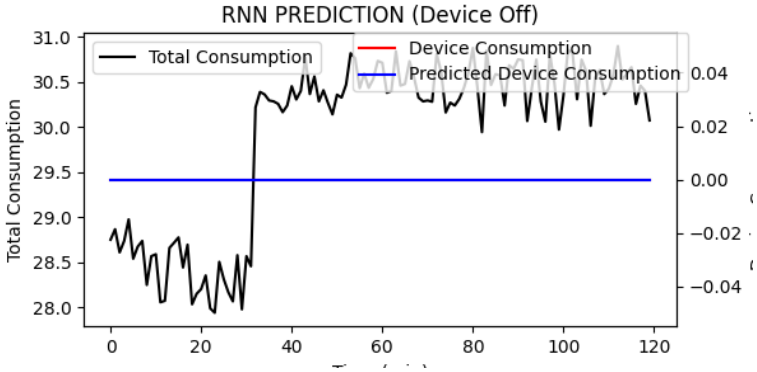

GRU PREDICTION (Device Off)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption
45
40
35
30
0.04
0.02
0.00
−0.02
−0.04
0
20
40
60
80
100
120

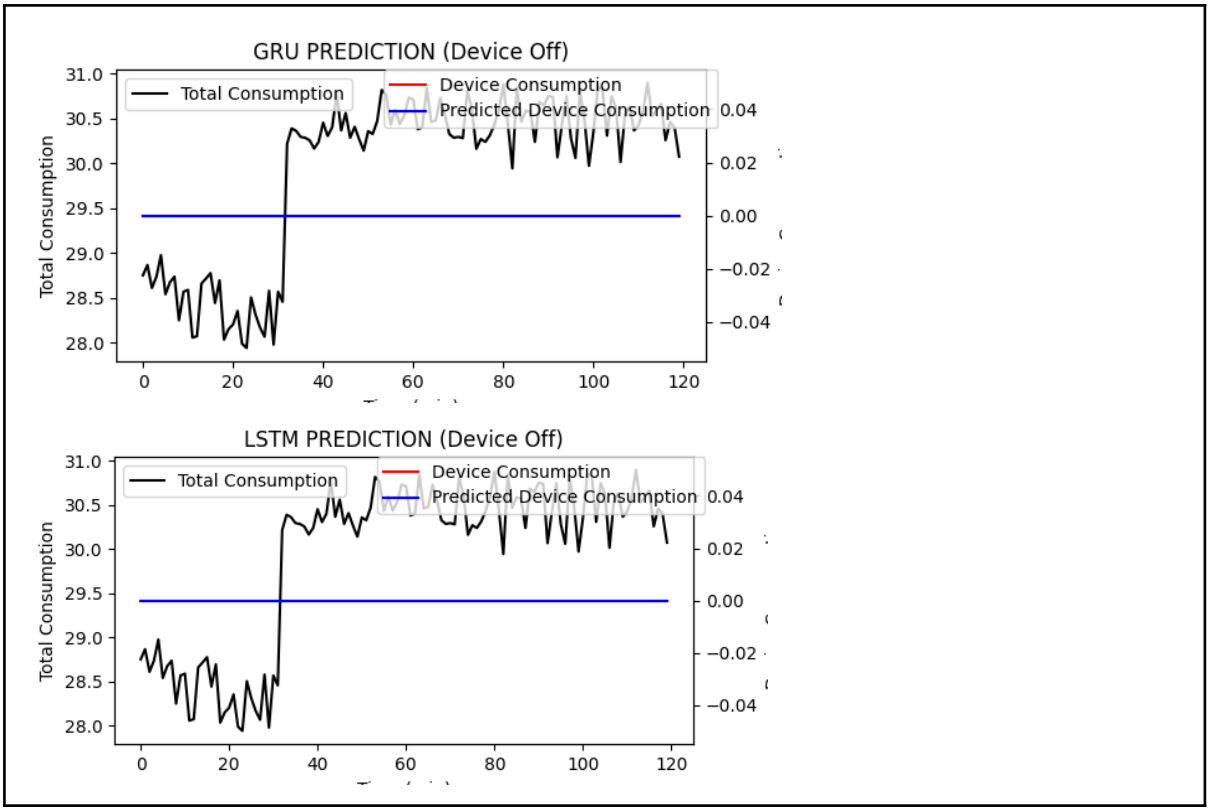

LSTM PREDICTION (Device Off)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption
45
40
35
30
0.04
0.02
0.00
−0.02
−0.04
0
20
40
60
80
100
120


RNN PREDICTION (Device Off)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption


GRU PREDICTION (Device Off)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption


LSTM PREDICTION (Device Off)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption


RNN PREDICTION (Device Off)
Total Consumption
Device Consumption
Predicted Device Consumption
Total Consumption



Παρατηρώντας τα αποτελέσματα, σίγουρα έχει γίνει μια ικανοποιητική πρόβλεψη που επιτρέπει την εξοικείωση μου με τις αρχιτκτονικές LSTM. Σίγουρα όμως παρατηρούνται αρκετές αστοχίες και ατέλειες που με περισσότερη προσπάθεια και δοκιμές νέων μοντέλων, αριθμό batches- συναρτησεις ενεργοποίησης κ.α τα αποτελέσματα θα μπορούσαν να βελτιωθούν. Θα έπρεπε να ήταν ορατή η καλύτερη συμπεριφορά των LSTM και GRU έναντι του απλού vanilla RNN αλλά αυτό δεν φαίνεται. Ειδικά, το GRU φαίνεται το καλύτερο μοντέλο.